

SOPHIA CELINE RAFAEL ALVES PEREIRA

**VALIDAÇÃO DE ALGORITMOS DE
FOTOPLETISMOGRAFIA REMOTA PARA
ESTIMATIVA DE SINAIS VITAIS DE PACIENTES
EM UNIDADES DE TERAPIA INTENSIVA**

São Paulo
2026

RESUMO

O monitoramento de sinais vitais é fundamental para a avaliação do estado fisiológico de pacientes e, tradicionalmente, é realizado por meio de dispositivos médicos de contato. Entretanto, abordagens de monitoramento não invasivo apresentam benefícios relevantes, tanto em contextos clínicos quanto não clínicos, ao possibilitarem maior conforto ao paciente, redução de riscos associados ao contato físico e maior flexibilidade de aplicação. Nesse contexto, a fotopletismografia remota (rPPG) destaca-se como uma abordagem promissora para a estimativa de parâmetros fisiológicos, como frequência cardíaca e respiratória, saturação de oxigênio e pressão arterial, a partir da detecção de variações cíclicas do sistema cardiovascular que podem ser extraídas a partir das mudanças sutis de intensidade dos elementos de cor de regiões da pele captadas por vídeo. Embora existam diversos métodos, tanto não supervisionados quanto baseados em aprendizado profundo, a maioria dos estudos é conduzida em cenários controlados, envolvendo predominantemente indivíduos saudáveis. Diante dessa limitação, este trabalho busca analisar o desempenho dos principais algoritmos de rPPG em vídeos de pacientes de uma Unidade de Terapia Intensiva (UTI) inserida no contexto do Sistema Único de Saúde (SUS) brasileiro. Ademais, propõe-se a construção de uma base de dados específica para esse cenário, composta por vídeos adquiridos por uma câmera de vídeo industrial e por sinais de referência obtidos diretamente de monitores multiparâmetros hospitalares. Por fim, os resultados visam avaliar a robustez e a viabilidade clínica dos métodos de rPPG em condições reais de cuidados intensivos.

Palavras-Chave fotopletismografia remota, unidade de terapia intensiva, sinais vitais.

ABSTRACT

Vital sign monitoring is essential for evaluating the physiological state of a patient and is typically performed using contact-based medical devices. Nonetheless, non-invasive monitoring approaches offer relevant benefits in both clinical and non-clinical settings by increasing patient comfort, reducing contact-associated risks, and providing greater flexibility of application. In this context, remote photoplethysmography (rPPG) has emerged as a promising technique for estimating physiological parameters such as heart rate, respiratory rate, oxygen saturation and blood pressure by detecting cyclical variations of the cardiovascular system which can be extracted from subtle changes in the color intensity of pixels from the skin region captured by video. Although several methods have been proposed, including unsupervised approaches and deep learning-based techniques, most studies are conducted under controlled conditions and involve predominantly healthy individuals. In view of this limitation, this work aims to assess the performance of the main rPPG algorithms using video recordings of patients in a public Intensive Care Unit (ICU) which is part of the Brazilian Unified Health System (Sistema Único de Saúde - SUS). In addition, a new dataset specific to this context is proposed, comprising video recordings acquired using an industrial video camera and reference signals collected directly from hospital multiparameter monitors. The results aim to assess the robustness and clinical feasibility of rPPG methods under realistic intensive care conditions.

Keywords remote photoplethysmography, intensive care unit, vital signs.

SUMÁRIO

1	Introdução	6
1.1	Objetivos	11
1.2	Justificativa	12
2	Revisão da literatura	13
2.1	Modelagem do comportamento óptico da pele	13
2.1.1	Lei de Beer-Lambert	13
2.1.2	Modelo Dicromático de Reflexão	15
2.2	Métodos não supervisionados	16
2.2.1	Métodos baseados em separação de sinais	16
2.2.2	Métodos baseados em modelos	17
2.3	Métodos baseados em aprendizado profundo	22
2.3.1	Redes neurais convolucionais	22
2.3.2	Redes neurais recorrentes	24
2.3.3	Redes adversárias generativas	25
2.3.4	Transformers	26
2.4	Fatores de influência na aquisição de imagens para fotopletismografia remota	26
2.4.1	Iluminação	27
2.4.2	Movimento	28
2.4.3	Detecção da região de interesse	29
2.4.4	Outros fatores	30
2.5	Estimativa de parâmetros fisiológicos	31
2.5.1	Frequência cardíaca	32
2.5.2	Variabilidade da frequência cardíaca	32

2.5.3	Frequência respiratória	33
2.5.4	Saturação periférica de oxigênio (SpO2)	34
2.5.5	Pressão arterial	35
3	Materiais e métodos	37
3.1	Aquisição de dados	37
3.1.1	Coleta 1	37
3.1.2	Coleta 2	39
3.1.3	Coletas futuras	40
3.2	Processamento de dados de vídeo	40
3.3	Processamento dos dados de referência	43
3.4	Métricas de avaliação	43
3.5	Construção da base de dados pública	45
4	Resultados preliminares	47
4.1	Coleta 1	47
4.1.1	Sincronização de dados	47
4.1.2	Sinal de rPPG	49
4.1.3	Estimativas de frequência cardíaca	49
4.1.4	Estimativas de frequência respiratória	53
4.2	Coleta 2	53
4.2.1	Sincronização dos dados	53
4.2.2	Estimativas de frequência cardíaca	54
5	Discussão preliminar	57
	Referências	59

1 INTRODUÇÃO

A medição de sinais vitais é uma prática essencial para a avaliação das condições fisiológicas de um indivíduo e para garantir tratamentos adequados e evitar a deterioração de condições de saúde que podem ser prevenidas (ELLIOTT; COVENTRY, 2012). Por esse motivo, no cenário clínico, especialmente no cuidado de pacientes de alto risco, há monitoramento contínuo com o uso de equipamentos médicos automatizados, a fim de possibilitar que mudanças significativas nos parâmetros fisiológicos possam ser prontamente identificadas e tratadas. A título de exemplo, a função cardíaca é tipicamente monitorada por meio do eletrocardiograma (ECG), ao passo que a frequência respiratória pode ser obtida por pneumografia por impedância, geralmente utilizando os mesmos eletrodos empregados na aquisição do ECG, enquanto a saturação de oxigênio é avaliada por oximetria de pulso.

No entanto, as restrições impostas pelo monitoramento contínuo por dispositivos com fios e contato direto com o corpo, principalmente durante períodos prolongados, podem gerar incômodo e são consideradas um dos fatores mais citados como agentes estressores para pacientes em Unidades de Terapia Intensiva (UTIs) (EDE et al., 2021). De fato, no contexto de Unidades de Terapia Intensiva Neonatal (UTINs), os dispositivos de medição requerem sensores adesivos que podem ocasionar lesões em recém-nascidos prematuros, os quais possuem a pele frágil, além de causar dor. Em contrapartida, soluções de medição de frequência cardíaca (FC), frequência respiratória (FR) e saturação de oxigênio por câmera mostram acurácia clinicamente significativa e comparável aos métodos tradicionais nesse cenário (VILLARROEL et al., 2014).

Ademais, o monitoramento em UTIs apresenta desafios sobretudo durante o transporte de pacientes e devido ao mau contato dos sensores ou à má qualidade do sinal. Nesse caso, a monitorização por câmera se mostra uma alternativa capaz de fornecer estimativas confiáveis das frequências cardíaca e respiratória e, principalmente, prever alterações no ritmo respiratório de forma condizente com o estado fisiológico em situações nas quais a aquisição por equipamentos de contato está ausente. Além disso, esse tipo de

solução complementa essas medições e pode oferecer informações visuais sobre a morfologia do esforço respiratório e evidenciar assimetrias que contribuem para o diagnóstico de condições clínicas (JORGE et al., 2022).

A partir disso, diante dos desafios impostos pela aquisição de sinais vitais por meio de equipamentos médicos de contato, a medição de parâmetros fisiológicos por câmera apresenta-se como uma estratégia confiável e possui vantagens de custo e facilidade de aplicação comparado a outras estratégias de monitorização remota, como as baseadas em indução magnética, efeito Doppler ou imageamento térmico (KHANAM et al., 2019). Nesse sentido, as soluções de medição por câmera baseiam-se, principalmente, em métodos de fotopletismografia remota (*Remote Photoplethysmography* - rPPG), os quais possuem o objetivo de detectar as variações cíclicas do sistema cardiovascular que podem ser extraídas a partir das mudanças sutis de intensidade dos elementos de cor de uma área do corpo ao longo do tempo. Assim, a luz que é re-emitida após passar pelos tecidos da pele é captada por dispositivos de aquisição de imagens, sendo que as propriedades óticas da superfície do corpo são influenciadas sobretudo pela hemoglobina e pela melanina da região analisada. Em função das características descritas, as principais aplicações utilizam não só câmeras RGB convencionais, mas também câmeras sensíveis ao infravermelho ou ao infravermelho próximo (SELVARAJU et al., 2022).

Dessa forma, a compreensão detalhada da fotopletismografia remota requer, inicialmente, a definição dos princípios básicos da fotopletismografia (PPG). A PPG é uma técnica ótica de medição que pode ser utilizada para detectar variações no volume sanguíneo no leito microvascular dos tecidos. Desse modo, o sinal característico dessa técnica possui uma componente pulsátil com frequência fundamental próxima a 1 Hz e que depende do batimento cardíaco, conforme ilustra a Figura 1. Analogamente, há uma componente que varia lentamente de acordo com a respiração, com a atividade vasomotora e com ondas vasoconstritoras, além de ondas Traube-Hering-Mayer (THM) relativas a oscilações da pressão arterial. Esse sinal pode ser percebido devido às características óticas da pele, sendo que os fatores primordiais que afetam a quantidade de luz recebida por um fotodetector de um tecido iluminado são o volume sanguíneo, a movimentação das paredes dos vasos e a orientação das células vermelhas. Há, ainda a influência do comprimento de onda da fonte na interação entre a pele e a luz, de modo que a medição convencional desse sinal, tipicamente realizada por oxímetros de pulso, utiliza feixes luminosos na faixa do vermelho e do infravermelho para detecção da saturação periférica de oxigênio baseada nas propriedades óticas de absorção da oxihemoglobina e da desoxihemoglobina nessas regiões do espectro eletromagnético (ALLEN, 2007).




Figura 1: Componente pulsátil do sinal de PPG e o ECG correspondente

Fonte: Allen (2007)

Diante do exposto, a literatura mostra que é possível obter um sinal de PPG de forma remota com o uso de câmeras convencionais e utilizando a luz ambiente como principal fonte de iluminação, por meio da análise das variações dos canais de cor de regiões de interesse (*Region Of Interest* - ROI) específicas, como o rosto, a testa ou as bochechas (VERKRUYSSSE et al., 2008). Além disso, a fim de definir princípios bem estabelecidos para a extração de sinais de rPPG, os principais métodos consideram a modelagem da interação entre a luz e a pele com base na lei de Beer-Lambert, a qual descreve como a absorção da luz por uma substância depende de sua concentração e do caminho percorrido pelo feixe, ou no modelo dicromático de reflexão de Shafer, o qual define que a luz refletida por um material dielétrico não homogêneo pode ser dividida em uma componente de reflexão difusa e uma componente de reflexão especular (CHEN; MCDUFF, 2018).

Nesse contexto, a extração do sinal de rPPG pode ser realizada tanto com o uso exclusivo de luz ambiente quanto por meio de fontes de iluminação controladas, com um ou mais dispositivos de aquisição de imagens para a captura de dados de vídeo (MCDUFF et al., 2015). A metodologia usual envolve a detecção e o rastreamento de uma ROI, a partir da qual é obtido o sinal bruto por meio da análise dos canais de cor dos pixels de cada frame. Posteriormente, esse sinal é filtrado e processado a fim de reconstruir a onda de pulso de volume sanguíneo (*Blood Volume Pulse* - BVP) característica da fotopletismografia, cujas propriedades podem ser utilizadas para a estimação de parâmetros fisiológicos (ROUAST et al., 2018), conforme esquematiza a Figura 2.




Figura 2: Esquemático da extração de sinais por fotopletismografia remota. 1) Imagens de regiões da pele, tipicamente do rosto, são capturadas sob iluminação natural ou artificial. 2) As regiões de interesse de cada imagem são segmentadas. 3) Os sinais dos canais de cor da câmera são processados para a obtenção da onda de BVP. 4) Parâmetros fisiológicos são extraídos a partir da onda de BVP resultante.

Fonte: Adaptado de McDuff et al. (2015)

Por conseguinte, as principais implementações utilizam métodos não supervisionados, bem como métodos baseados em aprendizado profundo (*deep learning*, DL). Os métodos não supervisionados extraem os sinais fisiológicos por estratégias de análise de cor ou de movimento das imagens de entrada. Sistemas baseados em DL, por sua vez, utilizam tanto modelos fim a fim, os quais são treinados para extraírem o sinal de rPPG ou diretamente parâmetros fisiológicos a partir de dados de vídeo como entrada, quanto sistemas híbridos, os quais combinam métodos algorítmicos com modelos de DL que extraem características específicas em uma ou mais partes do processo de estimação de parâmetros. Desse modo, pode-se extrair dados de perfusão sanguínea periférica, frequência respiratória, saturação de oxigênio, frequência cardíaca e de pulso, variabilidade das frequências cardíaca e de pulso e pressão arterial por meio das diferentes abordagens (CHEN et al., 2024).

Em vista disso, a extração do sinal de rPPG possui crescente potencial de aplicabilidade, por exemplo, no monitoramento dos parâmetros fisiológicos de pacientes em sessões de tratamento de hemodiálise. Nesse cenário, algoritmos de imageamento fotopletismográfico podem estimar valores de frequência cardíaca com boa concordância em relação aos adquiridos por equipamentos eletromédicos de referência (VILLARROEL et al., 2017; VILLARROEL et al., 2020). Adicionalmente, nesse mesmo contexto clínico, os sinais de frequência respiratória adquiridos por esses métodos podem ser considerados mais estáveis

que os obtidos com a utilização de cintas torácicas (TARASSENKO et al., 2014).

Outro tipo de aplicação envolve a detecção de fibrilação atrial com base no sinal de fotopletismografia obtido remotamente. Para isso, é possível analisar índices estatísticos de variabilidade da frequência cardíaca baseados no pulso extraído dos dados de vídeo dos indivíduos analisados (COUDERC et al., 2015). Ademais, pode-se utilizar modelos de aprendizado profundo para classificar os sinais de rPPG de pacientes, de modo a indicar se possuem essa condição, se possuem ritmo sinusal normal ou outros tipos de alterações no ritmo cardíaco (SUN et al., 2022).

Observa-se, ainda, que a medição de sinais vitais de forma remota possui relevância no contexto de missões de busca e resgate para triagem de vítimas, sendo que há implementações que envolvem a aquisição de vídeos por câmeras embarcadas em veículos aéreos não tripulados. A partir dessas imagens, é possível extrair sinais de frequência cardíaca e respiratória com boa concordância em relação a dispositivos de referência como transdutores piezoelétricos de cinta respiratória e oxímetros de pulso. Nesse caso, a utilização de algoritmos de redução de ruídos é essencial para minimizar a influência de variações de iluminação e da movimentação tanto da câmera quanto dos indivíduos monitorados (AL-NAJI et al., 2017).

De modo complementar, a fotopletismografia remota possui potencial de aplicação para disparo cardíaco em procedimentos de ressonância magnética. A obtenção da onda de rPPG pode ser utilizada para iniciar a captura de imagens em momentos específicos do ciclo cardíaco. Esse tipo de abordagem, sobretudo na aquisição realizada por equipamentos de campo ultra-alto, evita o contato físico e possui menor interferência de artefatos em relação à oximetria de pulso e ao eletrocardiograma, que são os principais métodos de contato utilizados nesse contexto (SPICHER et al., 2016).

O monitoramento remoto de parâmetros fisiológicos apresenta, adicionalmente, vantagens em relação a abordagens convencionais sobretudo no que se refere à realização de exercícios físicos, em que a medição por contato é dificultada (NAPOLEAN et al., 2022). Durante a prática esportiva, as frequências cardíaca e respiratória são importantes para o cálculo do índice de intensidade de atividade física o qual, por sua vez, possibilita uma análise do esforço realizado. Assim, é possível evitar lesões por meio da identificação de condições de fadiga extrema a partir desse índice, que pode ser obtido com base nos sinais extraídos por câmera (WU et al., 2023).

Com base nas discussões apresentadas, é observável a importância da aquisição de sinais vitais para acompanhamento do status fisiológico de indivíduos em diversos con-

textos. Desse modo, diante das limitações impostas pela medição por equipamentos convencionais, implementações de monitorização sem contato, sobretudo a fotopletismografia remota, apresentam significativo potencial a ser explorado principalmente no ambiente de cuidados a pacientes críticos. Por isso, esse projeto visa aplicar os principais algoritmos e estratégias de estimativa de parâmetros fisiológicos por rPPG em vídeos adquiridos de pacientes admitidos em uma UTI de uma instituição inserida no Sistema Único de Saúde (SUS), a fim analisar o desempenho desse tipo de solução no cenário de cuidado crítico.

Propõe-se, ademais, a disponibilização dos dados coletados, visando contribuir para o avanço da pesquisa científica no contexto da saúde pública brasileira, considerando a escassez de bases de dados representativas nesse cenário. Observa-se, ainda, que a maior parte das publicações científicas voltadas ao cuidado crítico é proveniente de países classificados pelo Banco Mundial como países de alta renda, o que resulta em uma sub-representação dos países de baixa e média renda (DALTRO-OLIVEIRA et al., 2025), apesar de esses países concentrarem parcela significativa da população mundial. Assim, busca-se contribuir para a ampliação da representatividade de populações e contextos clínicos frequentemente pouco explorados na literatura, além de fomentar o desenvolvimento e a avaliação de soluções de monitorização fisiológica remota dentro das realidades estruturais e epidemiológicas do sistema público de saúde de um país de média renda.

1.1 Objetivos

Este trabalho possui dois objetivos principais. Primeiramente, o desenvolvimento de uma base de dados para rPPG de pacientes admitidos na UTI do Hospital Universitário (HU) da Universidade de São Paulo (USP). Para isso, será realizada a coleta de vídeos e, simultaneamente, serão adquiridos os sinais correspondentes dos monitores multiparâmetros da instalação de saúde como valores de referência. A partir disso, objetiva-se, adicionalmente, reproduzir os principais algoritmos de fotopletismografia remota para estimativa de parâmetros fisiológicos e aplicá-los aos dados coletados, a fim analisar o desempenho dessas implementações em um ambiente realista de cuidado crítico brasileiro. Assim, discerne-se esses objetivos gerais em objetivos específicos:

- Coletar dados de vídeo e medições de referência correspondentes de pacientes em uma UTI inserida no SUS.
- Reproduzir os principais algoritmos não supervisionados de fotopletismografia remota.

- Reproduzir as implementações de rPPG baseadas em aprendizado profundo de maior relevância na literatura e que possuem modelos e parâmetros de acesso aberto.
- Avaliar os métodos reproduzidos nos dados coletados com base em métricas bem definidas.
- Comparar o desempenho obtido nos dados coletados com o desempenho em bases de dados disponíveis na literatura.

1.2 Justificativa

É visível o potencial e a ampla gama de aplicações de soluções de monitoramento sem contato baseadas em fotopletismografia remota. No entanto, as implementações nesse contexto possuem como limitação a escassez de estudos em condições realistas como em hospitais e clínicas, sendo que a literatura é baseada predominantemente em ambientes controlados e análises em indivíduos saudáveis (BAUTISTA et al., 2023; HARFORD et al., 2019). Em vista disso, este projeto visa contribuir com uma investigação sobre a aplicação da rPPG em um cenário real de forma inédita em uma instituição de saúde pública brasileira que faz parte do SUS, envolvendo pacientes críticos de forma a analisar o desempenho desse tipo de solução nesses casos, bem como disponibilizar a base de dados obtida para desenvolvimentos futuros.

A avaliação de algoritmos de rPPG em dados provenientes de uma UTI brasileira é fundamental para validar esse tipo de tecnologia em um contexto ainda pouco explorado, uma vez que a maioria das bases de dados utilizadas para medição fisiológica por câmera foi coletada predominantemente na China, nos Estados Unidos e em países europeus (LEE et al., 2024). Além disso, é possível verificar que a população idosa é sub-representada nos principais *datasets*, assim como há uma escassez expressiva de dados de pacientes com doenças cardiovasculares (KHAN; MOSTAFA, 2025), sendo que essas populações são predominantes no ambiente de cuidado intensivo brasileiro (AGUIAR et al., 2021) no qual a base de dados proposta está inserida. Desse modo, a avaliação de soluções de rPPG nesse tipo de cenário caracterizado por elevada variabilidade fisiológica torna-se essencial para investigar a aplicabilidade clínica desses modelos, uma vez que seu objetivo é estimar sinais vitais e detectar alterações fisiológicas relevantes para a identificação e o monitoramento de condições de saúde.

2 REVISÃO DA LITERATURA

A seguir será discorrido sobre os aspectos mais relevantes que envolvem a aplicação de soluções de fotopletismografia remota. Ademais, serão apresentados os principais algoritmos e modelos da literatura e suas características. Com essa revisão, espera-se estabelecer o contexto do desenvolvimento deste projeto de forma completa e esclarecedora.

2.1 Modelagem do comportamento óptico da pele

A implementação de métodos de rPPG é baseada em uma fonte de iluminação, seja ela natural ou artificial, a qual interage com o tecido biológico de modo que a luz re-emitada após essa interação contém o sinal de interesse a partir do qual podem ser extraídos parâmetros fisiológicos. Por isso, o desenvolvimento de algoritmos capazes de processar os dados captados por um dispositivo de aquisição de imagens para obter esse sinal faz necessário o equacionamento de modelos que descrevem os fenômenos ópticos da pele. Nesse sentido, a literatura cita duas principais abordagens, que serão discutidas em seguida.

2.1.1 Lei de Beer-Lambert

A Lei de Beer-Labert é um princípio da espectroscopia que explica como a quantidade de luz atenuada por uma substância depende de sua concentração e do caminho percorrido pelo feixe luminoso. A equação 2.1 descreve essa relação, sendo A a absorbância em um determinado comprimento de onda λ , ou seja, a quantidade de luz absorvida, ε a absortividade molar, que caracteriza a intensidade com que uma espécie química absorve luz, c a concentração da substância e l o comprimento do caminho percorrido pelo feixe.

$$A(\lambda) = \varepsilon(\lambda) \cdot c \cdot l(\lambda) \quad (2.1)$$

Assim, o modelo de absorbância da pele pode ser descrito conforme a equação:

$$A(\lambda) = v_m(\lambda)c_m + v_h(\lambda)c_h + A_0(\lambda) \quad (2.2)$$

em que v representa o produto $\varepsilon \cdot l$, A_0 denota a absorção basal cutânea, considerando a saturação de oxigênio do sangue arterial constante, e os índices h e m representam a contribuição da hemoglobina e da melanina, respectivamente, considerando que essas são as substâncias que influenciam de forma predominante as características da pigmentação da pele.

A absorbância também pode ser expressa em função da intensidade de luz incidente (E) e transmitida (L):

$$A = -\log_{10}\left(\frac{L}{E}\right) \quad (2.3)$$

Descreve-se, então, o modelo de formação da imagem de uma câmera, por meio do modelo da intensidade P_i de um pixel em uma posição (x, y) de uma imagem correspondente a uma área da pele captada por uma câmera em um canal $i = \{R, G, B\}$ como:

$$P_i(x, y) = k \int L(x, y, \lambda) S_i(\lambda) d\lambda \quad (2.4)$$

em que S_i refere-se à resposta espectral do sensor e k ao ganho da câmera (XU et al., 2014).

Alternativamente a esse modelo, baseado na luz absorvida em uma posição estática, é possível modelar esse sistema com base na luz refletida ao longo do tempo. Para isso, descreve-se a curva de reflexão da pele em um instante de tempo como:

$$R_s(\lambda) = a_m R_m(\lambda) + a_h R_h(\lambda) \quad (2.5)$$

em que R_s descreve a refletância espectral da pele, R_m e R_h são as componentes espectrais associadas à melanina e à hemoglobina, respectivamente, e a_m e a_h são coeficientes escalares que ponderam a contribuição relativa de cada componente.

A partir disso, modela-se em função do tempo o valor de um pixel da região da pele captado por um canal de cor de uma câmera de acordo com a equação 2.6 (LAM; KUNO, 2015).

$$C_i(t) = a_m a_I(t) \int R_m(\lambda) I(\lambda, t) S_k(\lambda) d\lambda + a_h(t) a_I(t) \int R_h(\lambda, t) I(\lambda, t) S_i(\lambda) d\lambda \quad (2.6)$$

Nesse caso, a_I é um fator escalar associado às variações temporais de iluminação, $I(\lambda, t)$ é o espectro normalizado da fonte luminosa e $S_i(\lambda)$ é a resposta espectral da câmera para o canal i .

2.1.2 Modelo Dicromático de Reflexão

Paralelamente, em vista dos conceitos da computação gráfica e da visão computacional, a interação da luz com materiais dielétricos, como a pele, é descrita em termos de componentes independentes de reflexão especular e de reflexão difusa (KLINKER et al., 1988). No contexto da fotopletismografia remota, a primeira refere-se à energia luminosa que não é absorvida pelos tecidos e não possui informações referentes à pulsação. A componente difusa, por sua vez, está associada a absorção e dispersão da luz após atravessar as camadas cutâneas.

Esse modelo é equacionado de acordo com a relação 2.7, em que C_k é referente a um canal de cor de um pixel k , I denota a intensidade luminosa, v_s e v_d referem-se, respectivamente, às componentes especular e difusa e v_n denota o ruído de quantização do sensor da câmera.

$$\mathbf{C}_k(t) = I(t) \cdot (\mathbf{v}_s(t) + \mathbf{v}_d(t)) + \mathbf{v}_n(t) \quad (2.7)$$

No que se refere à componente especular, pode-se expressar $\mathbf{v}_s(t)$ segundo a equação 2.8, sendo $\mathbf{u}_s$ o vetor unitário de cor do espectro da luz, s_0 a parte estacionária da reflexão especular e $s(t)$ a parcela variável induzida pelo movimento.

$$\mathbf{v}_s(t) = \mathbf{u}_s \cdot (s_0 + s(t)) \quad (2.8)$$

No que se refere à componente difusa, pode-se descrever $\mathbf{v}_d(t)$ segundo a relação 2.9, em que $\mathbf{u}_d$ denota o vetor unitário de cor do tecido cutâneo, d_0 é a intensidade de reflexão difusa estacionária, $\mathbf{u}_p$ é a intensidade de pulso relativa nos canais RGB e $p(t)$ é o sinal de pulso (WANG et al., 2016).

$$\mathbf{v}_d(t) = \mathbf{u}_d \cdot d_0 + \mathbf{u}_p \cdot p(t) \quad (2.9)$$

Visto isso, a modelagem da interação da pele com a luz realizada por meio das diferentes abordagens expostas nas equações 2.4, 2.6 e 2.7 permite o desenvolvimento de algoritmos que extraem o sinal de volume de pulso sanguíneo a partir das variações dos canais RGB captadas por uma câmera ao longo do tempo de uma região do tecido. Para isso, as diferentes abordagens, que serão doravante expostas, utilizam técnicas sobretudo para diminuir as influências dos artefatos de ruído e otimizar fontes específicas do sinal. Por fim, a estimativa de parâmetros fisiológicos pode ser realizada por meio do processamento posterior da forma de onda de BVP obtida.

2.2 Métodos não supervisionados

As primeiras implementações de sistemas de estimação de sinais vitais por fotopletiografia remota que tangem o escopo deste projeto baseiam-se sobretudo em algoritmos e modelos matemáticos cujo objetivo principal é tratar dados de vídeo de câmeras convencionais e extrair o sinal de forma a minimizar o ruído. Para isso, uma das soluções iniciais utilizou uma combinação de métodos de interpolação, derivação de primeira ordem, filtros digitais e análise espectral autorregressiva para processar o nível de intensidade dos pixels de uma ROI definida no rosto de indivíduos gravados por uma câmera com sensor CCD (*Charged-Coupled Device*). Essa análise permitiu a obtenção da frequência cardíaca e da frequência respiratória, as quais demonstraram boa correlação com medições realizadas por um oxímetro de pulso para indicação da frequência cardíaca e com um termistor para detecção de alterações na temperatura no fluxo de ar nasal (TAKANO; OHTA, 2007). Outra solução, em contrapartida, realizou uma análise espectral baseada na Transformada Rápida de Fourier (FFT) a partir da média espacial dos pixels de regiões do rosto de indivíduos gravados por uma câmera RGB. Nesse caso, foi possível determinar dados das frequências cardíaca e respiratória, além de propor a hipótese da influência predominante do canal de cor verde sobre o sinal de rPPG (VERKRUYSSSE et al., 2008).

2.2.1 Métodos baseados em separação de sinais

Desenvolvimentos subsequentes buscaram procurar aumentar a separabilidade entre o sinal fisiológico de interesse e componentes associadas a ruído, movimento ou variações de iluminação por meio de técnicas de separação cega de sinais (BSS - *blind source separation*). Esse tipo de abordagem visa a recuperação de sinais-fonte a partir de observações que correspondem a uma mistura dessas fontes. Em BSS, costuma-se partir de um modelo de mistura: $\mathbf{C}(t) = \mathbf{A} \cdot \mathbf{S}(t) + \mathbf{n}(t)$, em que $\mathbf{C}(t)$ é o vetor de sinais observados,

$\mathbf{S}(t)$ é o vetor de fontes latentes, $\mathbf{A}$ é a matriz de mistura e $\mathbf{n}(t)$ representa ruído ou componentes não modeladas. A equação 2.10 enuncia esse conceito, de forma que $\mathbf{Y}(t)$ refere-se aos sinais-fonte, $\mathbf{C}(t)$ é o sinal observado e $\mathbf{W}$ é uma matriz de separação. No contexto da fotopletismografia remota, a fonte é o sinal de pulso de volume sanguíneo e a informação observada corresponde à variação dos canais de cor captada por uma câmera, que contém os artefatos de ruído relacionados a movimento, iluminação, características ópticas da pele e ruído de aquisição.

$$\mathbf{Y}(t) = \mathbf{W} \cdot \mathbf{C}(t) \quad (2.10)$$

Assim, uma das maneiras de estimar a matriz de separação que permite a obtenção do sinal de interesse é por Análise de Componentes Independentes (ICA) sob a hipótese de independência estatística das fontes. Esse método consiste na recuperação de sinais independentes a partir de observações compostas por combinações lineares das fontes desconhecidas. Especificamente em soluções de rPPG, uma das abordagens utiliza diagonalização conjunta aproximada de matrizes (CARDOSO, 1999) a fim de decompor o sinal normalizado dos canais RGB em três fontes independentes. A partir dessas fontes, é realizada a análise espectral baseada em FFT para obtenção da frequência cardíaca (POH et al., 2010b) ou, ainda, de sua variabilidade, bem como da frequência respiratória (POH et al., 2010a).

Outro método baseado em separação de sinais que permite estimar o sinal fisiológico de interesse é por Análise de Componentes Principais (PCA). Essa técnica é tipicamente utilizada para redução de dimensionalidade de conjuntos de dados para reconhecimento estatístico de padrões e processamento de sinais, de modo que determina combinações lineares ortogonais de variáveis originais que maximizam a variância dos dados projetados. No contexto da fotopletismografia remota, a PCA pode ser empregada para decompor os sinais obtidos a partir dos canais de cor em componentes não correlacionadas, podendo evidenciar a componente associada à atividade cardiovascular e, conseqüentemente, a identificação da frequência cardíaca com custo computacional menor e com desempenho reportado como comparável ao da ICA em determinadas condições experimentais (LEWANDOWSKA; NOWAK, 2012).

2.2.2 Métodos baseados em modelos

Os métodos baseados em BSS são soluções matemáticas e computacionais para processamento de sinais e, no entanto, não incorporam explicitamente as especificidades do

comportamento óptico do sinal de rPPG. Por isso, implementações posteriores baseadas em modelos fundamentam-se essencialmente na modelagem de vetores de cor de diferentes componentes para extração das informações de pulso a partir do sinal captado por câmeras RGB.

Uma dessas implementações é a técnica baseada em cromaticidade (HAAN; JEANNE, 2013), a qual estipula, a partir do modelo dicromático de reflexão, que artefatos de movimento geram variações na componente de reflexão especular, as quais dependem do ângulo entre a câmera, a pele e a fonte de luz e são aproximadamente idênticas para todos os canais de cor R , G e B referentes ao vermelho, verde e azul, respectivamente. Assim, esse algoritmo, daqui em diante referido como CHROM, busca atenuar a influência da componente especular e de perturbações comuns aos três canais, por meio da utilização de dois sinais de cromaticidade ortogonais $X = R - G$ e $Y = 0.5R + 0.5G - B$, relativos às diferenças entre os sinais de cor, o que pode aumentar a robustez da extração frente a perturbações comuns aos canais de cor. Essa abordagem estabelece, ademais, uma direção de cor de pele padronizada no espaço RGB normalizado, obtida empiricamente, assumindo que a cor média da pele, após normalização, apresenta uma orientação relativamente estável sob iluminação branca. Essa hipótese, exposta na equação 2.11, permite construir projeções de cromaticidade menos sensíveis à intensidade luminosa, mas não elimina completamente a dependência em relação ao espectro da iluminação, à câmera e às características individuais da pele.

$$S = X_f - \alpha Y_f \quad \text{com} \quad \alpha = \frac{\sigma(X_f)}{\sigma(Y_f)} \quad (2.11)$$

Nessa relação, S é a estimativa do sinal de pulso, X_f e Y_f são os sinais de cromaticidade normalizados em função do vetor padrão de cor de pele X_s e Y_s filtrados por um filtro passa-banda, $\sigma(\cdot)$ é o operador de desvio padrão e α é um fator de correção que mantém os sinais X e Y com amplitudes similares de forma que o ruído especular possa ser efetivamente eliminado. Mais especificamente, define-se:

$$\begin{aligned} X_s &= 3R_n - 2G_n \\ Y_s &= 1.5R_n + G_n - 1.5B_n \end{aligned} \quad (2.12)$$

onde R_n , G_n e B_n são os canais referentes ao vermelho, verde e azul, respectivamente, normalizados pelas médias correspondentes.

Outro método, denominado PBV (HAAN; LEEST, 2014), baseia-se na análise de que

os diferentes espectros de absorção do sangue arterial e do tecido cutâneo causam variações em um vetor característico no espaço RGB normalizado. A partir disso, a definição desse vetor padrão de pulso de volume sanguíneo, $\vec{P}_{bv}$, reflete as amplitudes relativas do sinal de pulso nos canais de cor e depende do espectro de iluminação, da reflectância da pele e dos filtros ópticos da câmera, conforme as equações 2.13 e 2.14, em que λ é o comprimento de onda, H_c é a resposta de um canal c da câmera RGB, ρ_s é a reflectância da pele, $I(\lambda)$ é a composição espectral da fonte de luz e $I_h(\lambda)$ é o espectro contínuo de emissão da lâmpada de halogênio utilizada para medir a amplitude $PPG(\lambda)$ do sinal de rPPG.

$$\vec{P}_{bv} = [P_c], \quad c \in \{R, G, B\} \quad (2.13)$$

$$P_c = \frac{\int_{400}^{700} H_c(\lambda) \cdot \frac{I(\lambda)}{I_h(\lambda)} \cdot PPG(\lambda) \cdot d\lambda}{\int_{400}^{700} H_c(\lambda) \cdot \frac{I(\lambda)}{I_h(\lambda)} \cdot \rho_s(\lambda) \cdot d\lambda} \quad (2.14)$$

Assim, o algoritmo busca encontrar pesos $\vec{W}_{PBV}$ que fazem com que o sinal $\vec{S}$ tenha correlação com os canais de cor normalizados $C_n \in \{\vec{R}_n, \vec{G}_n, \vec{B}_n\}$ de forma proporcional ao vetor definido, conforme a equação 2.15.

$$\vec{S} C_n^T = k \vec{P}_{bv} \Leftrightarrow \vec{W}_{PBV} C_n C_n^T = k \vec{P}_{bv} \quad (2.15)$$

A técnica de rotação de subespaço espacial (*Spatial Subspace Rotation*, 2SR) (WANG et al., 2015), por sua vez, define um subespaço que considera a distribuição dos pixels relativos à pele no espaço RGB de modo específico à cada dado de vídeo. Dessa forma, temporalmente, as mudanças nos canais de cor causadas pela pulsação sanguínea geram variações de rotação nesse subespaço. O sucesso desse algoritmo, no entanto, depende de uma máscara bem definida da região da face.

De forma análoga, o modelo de plano ortogonal à pele (*Projection Orthogonal to Skin*, POS) (WANG et al., 2016) propõe um plano de projeção ortogonal ao vetor de tom de pele no espaço RGB normalizado temporalmente, no qual supõe-se que as componentes especular e difusa possuem distribuições distintas e podem, portanto, ser desagregadas. A equação 2.16 expõe a relação desse plano, cuja matriz de projeção é denominada $\mathbf{P_P}$, para a obtenção do sinal de pulso $\mathbf{S}(t)$ a partir dos canais de cor normalizados $\mathbf{C_n}(t) = \{R_n(t), G_n(t), B_n(t)\}$.

$$\mathbf{S}(t) = \mathbf{P_P} \cdot \mathbf{C_n}(t) \quad (2.16)$$

Assim, a projeção dos canais sobre os eixos ortogonais de $\mathbf{P_P}$ resulta em dois sinais S_1 e S_2 que contêm o comportamento pulsátil do sinal e são definidos em função da amplitude dos canais de cor, sendo que, para uma única fonte, considera-se que a pulsatilidade dos tecidos cutâneos é observada de forma mais acentuada no canal verde, seguido do azul e é menos evidente no canal vermelho, sob condições usuais de iluminação e aquisição com câmeras RGB. Consequentemente, pode-se escrever esses eixos conforme a equação 2.17.

$$S(t) = \begin{pmatrix} S_1(t) \\ S_2(t) \end{pmatrix} \quad \text{com} \quad \begin{cases} S_1(t) = G_n(t) - B_n(t) \\ S_2(t) = G_n(t) + B_n(t) - 2R_n(t) \end{cases} \quad (2.17)$$

Similarmente ao CHROM, esse algoritmo utiliza um fator de correção α para ajustar a escala relativa entre as duas componentes projetadas S_1 e S_2 , de forma que a obtenção do sinal de rPPG $h(t)$ é, então, obtida pela combinação linear dessas componentes, conforme exposto pela equação 2.18.

$$h(t) = S_1(t) + \alpha \cdot S_2(t) \quad \text{com} \quad \alpha = \frac{\sigma(S_1)}{\sigma(S_2)} \quad (2.18)$$

Em contraste, o método de invariância local a grupo (*Local Group Invariance*, LGI) (PILZ et al., 2018) propõe a construção de uma representação de características invariante a transformações locais, como movimento facial e variações de iluminação. Para isso, modela-se o sinal RGB como um processo aleatório multivariado e utiliza-se a matriz de covariância das transformações para identificar direções de maior variabilidade associadas a fatores de interferência. A partir de uma decomposição espectral, projeta-se o sinal no subespaço ortogonal a essas direções, obtendo-se uma representação mais robusta ao ruído. Em seguida, o sinal transformado é modelado como um processo oscilatório estocástico, capaz de capturar a natureza quase-periódica e não estacionária da frequência cardíaca, por meio do qual esse parâmetro pode ser estimado.

Complementarmente, o algoritmo de transformação de imagem por matriz ortogonal (*Orthogonal Matrix Image Transformation*, OMIT) (CASADO; LÓPEZ, 2023) gera sinais RGB não correlacionados por meio de decomposição QR. Para isso, toma-se a matriz dos canais de cor, uma base ortonormal e uma matriz triangular que contém coeficientes para expressar as colunas da matriz dos canais como uma combinação linear dos vetores da base. Assim, a matriz da base é utilizada para obter uma matriz de projeção que permite a extração da onda de pulso de volume sanguíneo a partir dos dados de cor de entrada. Em adição, esse estudo introduz um fluxo de processamento que inclui uma malha de

detecção de pontos da face a qual permite a consistência na extração dos sinais ao longo do tempo, além de uma técnica de seleção dinâmica de regiões do rosto baseada em análise fractal de forma a descartar partes que contribuem negativamente para o sinal, compostas, por exemplo, por má iluminação, oclusão ou borramentos. Desse modo, a otimização da definição da ROI, somada ao algoritmo de extração do sinal baseado em decomposição de matrizes, contribui para a otimização da relação sinal-ruído e garante robustez a artefatos de movimento e iluminação. Esse algoritmo é expresso pela equação:

$$\mathbf{A} = \mathbf{Q} \cdot \mathbf{R} \quad (2.19)$$

em que $\mathbf{A}$ é a matriz construída a partir dos sinais dos canais de cor, $\mathbf{Q}$ é uma base ortonormal e $\mathbf{R}$ é uma matriz triangular superior de coeficientes.

Há, ainda, métodos que utilizam o espaço de cor de matiz, saturação e valor (HSV), em contrapartida ao espaço RGB. Nesse contexto, a análise espectral especificamente do canal de matiz permite a extração das frequência cardíaca e respiratória com boa correspondência em relação a outros métodos de medição, de forma comparável ao obtido por meio da análise dos canais de vermelho, verde e azul (SANYAL; NUNDY, 2018). No mesmo raciocínio, outros estudos mostraram a vantagem de usar esse espaço para obtenção de sinais de pulso com uso de técnicas de ICA (TSOURI; LI, 2015).

Em resumo, as abordagens não supervisionadas visam equacionar o sinal dos canais de cor a fim de distinguir as componentes que carregam informações de pulsação sanguínea das componentes de ruído. Para isso, as técnicas de BSS focam em estimar as fontes de entrada e, no entanto, podem falhar quando há movimento periódico na região de interesse, já que pressupõem que a componente pulsátil seja suficientemente distinta dos demais termos espectrais. Os algoritmos baseados em modelos, por sua vez, focam na extração da variação relativa do sinal, de modo que o CHROM visa reduzir variações associadas à iluminação e à reflexão especular, preservando a componente pulsátil, ao modelar o espectro de iluminação e eliminá-lo do sinal. Já o PBV estabelece um vetor de pulso padrão e possui como objetivo projetar o sinal na direção desse vetor. Similarmente, o POS projeta o sinal em um plano ortogonal ao vetor de tom de pele padronizado. O método 2SR, por sua vez, visa estimar a frequência de variação do volume sanguíneo por meio da análise da rotação do sinal projetado em um subespaço dos canais RGB, todavia a definição desse subespaço depende de cada dado de forma específica. Por fim, os métodos LGI e OMIT procuram modelar os ruídos de iluminação e movimento, sendo que o primeiro o faz utilizando transformações locais baseadas em noções de invariância a fim

de estimar a direção desses artefatos e o segundo utiliza decomposição QR para construir uma base ortonormal e uma projeção dos sinais de cor, com o objetivo de realçar a componente pulsátil e reduzir contribuições indesejadas. Esses métodos, portanto, fornecem diferentes estratégias para estimar o sinal de BVP a partir das séries temporais dos canais de cor captadas por câmera

2.3 Métodos baseados em aprendizado profundo

O aprendizado profundo baseia-se na utilização de redes neurais artificiais para analisar conjuntos de dados e identificar padrões complexos. O processo de aprendizagem é feito por meio do treinamento de modelos com o objetivo de minimizar o erro entre os resultados previstos por esses modelos e os esperados. Assim, esse tipo de estratégia é denominada supervisionada, uma vez que faz necessária a utilização de conjuntos de dados de treinamento e teste com valores de referência.

No contexto da fotopletismografia remota, soluções desse tipo requerem quantidades significativas de dados de treinamento, além de que a maioria das bases de dados foca em artefatos de movimento e mudanças de iluminação, sendo que outros fatores de influência, como diferentes tons de pele e monitoramento em longas distâncias, também são relevantes para o desenvolvimento de implementações em cenários reais. Ademais, são poucos estudos que disponibilizam de forma completa e acessível os códigos, pesos treinados e hiperparâmetros e os conjuntos de dados utilizados, o que limita a reprodutibilidade e a comparação direta entre métodos. Todavia, os resultados obtidos são expressivos e superam aqueles alcançados por métodos não supervisionados baseados em modelos (CHENG et al., 2021; XIAO et al., 2024; CHEN et al., 2024). Nesse sentido, o estudo de soluções de extração de sinais de rPPG baseadas em aprendizado profundo faz necessário o entendimento das diferentes técnicas e suas aplicações, o que será detalhado a seguir.

2.3.1 Redes neurais convolucionais

Redes neurais convolucionais (CNNs) são algoritmos de DL especializados no processamento de dados visuais por meio de extração de características e reconhecimento de padrões. As primeiras implementações desse tipo de algoritmo aplicado à rPPG utilizam redes bidimensionais (2D) capazes de identificar padrões espaciais em imagens. Assim, uma das implementações demonstra que é possível aplicar uma CNN 2D ao processamento quadro a quadro da face para extrair uma sequência temporal escalar análoga ao sinal

de rPPG, treinada de modo a maximizar sua relação sinal-ruído em torno da frequência cardíaca de referência. Em seguida, essa sequência pode ser utilizada para estimar a frequência cardíaca, como proposto pelo modelo HR-CNN (ŠPETLÍK et al., 2018). Similarmente, o modelo DeepPhys (CHEN; MCDUFF, 2018) utiliza CNNs para introduzir um modelo de aparência e um de movimento, no qual mecanismos de atenção orientam a aprendizagem de representações de movimento a partir das diferenças normalizadas entre quadros consecutivos, atribuindo maior peso às regiões da pele com sinais fisiológicos mais fortes para aprimorar a estimativa da onda de pulso de volume sanguíneo e das frequências cardíaca e respiratória.

As CNNs bidimensionais, quando aplicadas isoladamente a quadros independentes, capturam apenas padrões espaciais e não modelam explicitamente as dependências temporais entre quadros, o que é essencial para a obtenção de sinais de pulso de forma remota. Com base nisso, foram desenvolvidas estratégias para incluir as características sequenciais do sinal, como o desenvolvimento do modelo de rede convolucional multitarefas MTTS-CAN (*Multi-task temporal shift convolutional attention network*) (LIU et al., 2020), realizado utilizando módulos de deslocamento temporal, de forma que os tensores 2D são deslocados ao longo da dimensão do tempo, a fim de extrair informações sequenciais entre múltiplos quadros para estimativa das frequências cardíaca e respiratória. De modo análogo, o modelo Synrhythm (NIU et al., 2018) utiliza uma representação espaço-temporal de vídeos do rosto como entrada de uma rede convolucional para estimativa de frequência cardíaca, assim como o modelo Rythmnet (NIU et al., 2019) o qual, por sua vez, também considera a relação entre estimativas subsequentes por meio de uma unidade recorrente com portão (GRU, *Gated Recurrent Unit*) e é baseado no espaço de cor YUV. Outras implementações consideram, em contraste com a utilização diretamente dos sinais de cor, sinais de pulso obtidos por meio de algoritmos não supervisionados, como POS e CHROM, como base para a construção dos mapas espaço-temporais, a partir dos quais pode ser realizada a estimativa da frequência cardíaca por uma rede neural convolucional 2D (SONG et al., 2020b; LU; HAN, 2021).

Avanços subsequentes na área de aprendizado profundo permitiram o desenvolvimento de modelos de CNN tridimensionais o que, apesar de introduzir maior custo computacional, resultou em uma evolução na performance desse tipo de solução, quando comparado aos métodos com redes 2D que são combinados com outros modelos para captar as características temporais (YU et al., 2019a). Isso se deu devido à possibilidade de reconhecer padrões espaciais e temporais simultaneamente, a exemplo do modelo Physnet (YU et al., 2019a), cuja versão que utiliza uma CNN 3D é capaz de extrair informações direta-

mente dos quadros do rosto para realizar inferências em vídeos sem pré processamento e retornar o sinal de rPPG correspondente com resultados superiores à versão do modelo baseada em redes bidimensionais. De modo similar, outra implementação incorpora redes convolucionais tridimensionais na arquitetura de um modelo definido como STVEN (*Spatio-Temporal Video Enhancement Network*) o qual é treinado para aperfeiçoar dados de vídeo a fim de lidar com artefatos de compressão, e na arquitetura de outro modelo denominado rPPGnet que extrai os sinais de pulso a partir do vídeo aperfeiçoado (YU et al., 2019b).

Ainda nesse contexto, outra abordagem propõe o modelo ETA-rPPGNet (HU et al., 2021), que emprega uma CNN 3D combinada com mecanismos de atenção temporal para segmentar vídeos, extrair características faciais relevantes e modelar correlações temporais, reduzindo a influência de ruído na extração do sinal de rPPG. No mesmo sentido, o modelo Siamese-rPPG (TSOU et al., 2020) foca na redução da influência de ruídos ao combinar a extração simultânea do sinal de duas regiões diferentes da face por meio do uso de redes siamesas, as quais correspondem a arquiteturas de sub-redes idênticas que compartilham os mesmos pesos e parâmetros. Esse mesmo processo pode ser realizado, ainda, com múltiplas regiões customizadas que são introduzidas em um modelo tridimensional referido como DeeprPPG (LIU; YUEN, 2020). Nesse caso, a extração do sinal de pulso é feita de forma a reduzir a influência de áreas contaminadas por artefatos por meio de uma estratégia de agregação espaço-temporal que combina adaptativamente os sinais provenientes dessas regiões.

2.3.2 Redes neurais recorrentes

As redes neurais recorrentes (RNNs) são capazes de relacionar informações sequenciais e são comumente utilizadas para relacionar dados temporais. Dois principais tipos de redes recorrentes são os modelos de LSTM (*Long Short-Term Memory*), os quais são capazes de aprender dependências de longo prazo em dados sequenciais, e os modelos de GRU, que correspondem a uma versão simplificada dessa arquitetura. Esse tipo de abordagem é comumente utilizada para extração de características temporais de sinais de fotopletismografia remota em combinação com modelos que processam informações espaciais, a exemplo do Rythmnet (NIU et al., 2019) mencionado anteriormente.

Ademais, a análise temporal possibilitada por modelos de LSTM pode ser utilizada para a filtragem do sinal de rPPG obtido por métodos não supervisionados, de forma a gerar uma forma de onda com menos ruído e melhor qualidade a partir da onda de

BVP inicial (BIAN et al., 2019; BOTINA-MONSALVE et al., 2020). Esse tipo de rede pode ser utilizada, ainda, para extrair características globais em conjunto com uma CNN tridimensional responsável por reconhecer padrões locais nos vídeos de entrada, como é implementado no modelo denominado PRnet (HUANG et al., 2021). Similarmente, o modelo Meta-rPPG (LEE et al., 2020) baseia-se em uma CNN para extração de características visuais combinada com um modelo de LSTM para estimação do sinal de pulso, com a distinção de que essa implementação também introduz uma estratégia de meta-aprendizado que permite a adaptação a dados com uma distribuição diferente daqueles utilizados para o treinamento.

2.3.3 Redes adversárias generativas

Redes Adversárias Generativas (GANs) constituem uma arquitetura de aprendizado profundo na qual duas redes neurais, denominadas gerador e discriminador, são treinadas de forma adversarial, competindo entre si com o objetivo de gerar dados sintéticos realistas a partir de um conjunto de treinamento. Esse tipo de rede pode ser utilizada para aperfeiçoar a detecção da região de interesse para a extração de sinais de rPPG, conforme é implementado no modelo referido como Deep-HR (SABOKROU et al., 2021). Nesse caso, a rede geradora é treinada para gerar a ROI que resulta no sinal de melhor qualidade, considerando que a região utilizada tem influência significativa nos resultados obtidos.

De modo similar, outras abordagens utilizam modelos de redes adversárias para obter um sinal de rPPG com a menor interferência de artefatos. Isso pode ser feito por meio da filtragem de um sinal cru gerado por métodos não supervisionados, como é implementado no desenvolvimento do modelo PulseGAN (SONG et al., 2021), no qual a rede geradora tem o objetivo de retornar a onda de BVP com a melhor qualidade a partir do sinal extraído pelo método CHROM. De forma análoga, o modelo Dual-GAN (LU et al., 2021) foca na modelagem dos elementos que interferem na onda de pulso de volume sanguíneo obtida remotamente. Para isso, são treinadas duas GANs diferentes, uma denominada BVP-GAN, que é especializada em obter o sinal de pulso de melhor qualidade, enquanto a outra, referida como Noise-GAN, tem o objetivo de aprender a distribuição do ruído, a fim de eliminar essa parcela do sinal e isolar a componente fisiológica mesmo em dados expressivamente ruidosos.

2.3.4 Transformers

Os modelos de Transformers foram introduzidos como uma alternativa às redes neurais recorrentes, de modo que permitem um processamento paralelo e mais eficiente de dados sequenciais por meio da implementação de mecanismos de atenção. Esse tipo de arquitetura de rede teve sua aplicação em problemas de processamento de dados visuais consolidada após o desenvolvimento dos chamados Transformers Visuais (*Vision Transformers* - ViT). Nesse sentido, os ViTs, diferente das redes neurais convolucionais que processam pixels localmente, são capazes de analisar múltiplos fragmentos de uma imagem simultaneamente, capturando dependências globais e contextos amplos com alta eficiência computacional e de forma a apresentar resultados expressivos em tarefas nesse contexto (DOSOVITSKIY et al., 2021).

Visto isso, essa estratégia foi implementada no contexto da fotopletiografia remota no desenvolvimento do modelo PhysFormer (YU et al., 2022), o qual utiliza um Transformer Visual para explorar relações espaço-temporais de longo alcance na estimativa de sinais de rPPG. Essa solução emprega diferenças temporais para orientar mecanismos de atenção global e refinar representações espaço-temporais locais, de modo a garantir robustez da extração do sinal diante de artefatos de ruído. De maneira semelhante, o modelo EfficientPhys (LIU et al., 2023) utiliza uma arquitetura de Swin Transformer, que corresponde a um ViT 2D o qual utiliza janelas deslocadas e introduz maior eficiência computacional, em conjunto com uma estratégia de deslocamento temporal similar à utilizada no modelo MTTs-CAN (LIU et al., 2020) para garantir a extração de características temporalmente.

2.4 Fatores de influência na aquisição de imagens para fotopletiografia remota

A aquisição de sinais biomédicos possui inerentemente a influência de fatores relacionados à interface de medição e aos sensores utilizados. No contexto da fotopletiografia remota, uma vez que o sinal de interesse tem base óptica, esses fatores estão associados à luz que é refletida pela pele e captada pelo dispositivo de medição, sendo que os artefatos observados têm origem sobretudo da fonte de iluminação e de artefatos de movimento. Além disso, verifica-se que as características do sensor óptico e do processo de aquisição, os algoritmos de compressão de dados, a distância entre a câmera e o indivíduo analisado e a seleção da região de interesse também interferem no sinal obtido (MCDUFF et al.,

2015; SINHAL et al., 2019). Desse modo, a análise aprofundada da aquisição de imagens para extração da onda de rPPG requer a compreensão desses fatores, o que será abordado a seguir.

2.4.1 Iluminação

A influência da iluminação na aquisição de sinais por imageamento fotopletismográfico se dá essencialmente devido à componente de reflexão especular do sinal, a qual relaciona-se justamente com o espectro e a intensidade da fonte de luz e não carrega informações referentes à componente cardiogênica. Assim, observa-se que a intensidade dessa componente, bem como sua direção de propagação, definida pelo posicionamento entre a fonte de iluminação e o dispositivo de medição, interferem na relação sinal-ruído de forma significativa (GULER et al., 2022; FAN et al., 2024). Verifica-se, ainda, que a acurácia da estimativa da frequência cardíaca e a contribuição do ruído especular dependem do espectro de cor da fonte (LIN; LIN, 2017).

Nesse sentido, diferentes estratégias têm sido propostas para reduzir a influência de artefatos de iluminação no sinal de rPPG. De fato, é possível, a fim de identificar e eliminar as mudanças na iluminação ambiente, empregar um filtro adaptativo normalizado de mínimos quadrados para correlacionar a variação da intensidade dos pixels no canal de verde do cenário de fundo com a mesma variação na região de interesse, considerando que ambos estão sob a mesma fonte de iluminação e podem ser aproximados como superfícies Lambertianas, ou seja, superfícies difusas que refletem a luz de forma uniforme (LI et al., 2014). Similarmente, pode-se utilizar separação cega de sinais conjunta para identificar as variações comuns de iluminação entre a ROI e o fundo, a fim de eliminar a contribuição dessa parcela do sinal (CHENG et al., 2016). Ademais, outras abordagens utilizam um filtro de média móvel para eliminar influência de mudanças na intensidade de luz captada em conjunto com um Filtro de Kalman com Mínimos Quadrados Ponderados para atenuação do ruído especular não estacionário e de alta variância, assumindo que essa componente afeta todos os canais de cor igualmente (LI et al., 2025).

Além das interferências associadas à reflexão especular e às variações na intensidade luminosa, as condições de iluminação também podem comprometer a representação correta dos pixels nas imagens adquiridas. Esse problema ocorre quando a intensidade luminosa incidente é excessiva ou insuficiente, fazendo com que os valores de intensidade ultrapassem ou não atinjam o intervalo representável pelo sensor, o qual se dá tipicamente entre 0 e 255 em imagens de 8 bits, o que resulta em saturação ou subexposição e prejudica

significativamente a relação sinal-ruído. Em vista disso, demonstra-se que pode-se utilizar um algoritmo de ganho adaptativo que ajusta o ganho analógico dos canais de cor e compensa variações extremas de intensidade de luz na extração de sinais de rPPG por meio de métodos como o CHROM (PAPAGEORGIOU; HAAN, 2014).

2.4.2 Movimento

Artefatos de movimento são um dos maiores desafios na extração de sinais de rPPG e estão relacionados a movimentações dos músculos da face, como falar e sorrir, ou até movimentos corporais mais amplos. Por causa desses fatores, a região de interesse, na qual são analisados os canais de cor, e a intensidade dos pixels que a compõe são modificadas ao longo do tempo, de forma que são introduzidos elementos não relacionados à componente cardiogênica do sinal (HASSAN et al., 2017). Por conseguinte, o desenvolvimento de métodos que reduzem a influência desse tipo de artefato é essencial para a implementação de soluções de extração de sinais de fotopletismografia remota em cenários realistas.

Nesse raciocínio, pode-se realizar a análise dos dados no espaço de cor CIELab, no qual o canal L indica a intensidade da imagem e os canais a e b descrevem a cromaticidade. Nesse espaço, as componentes de cor refletem as propriedades ópticas da hemoglobina do sangue, ao passo que artefatos de movimento afetam de forma mais acentuada o canal L. Desse modo, a análise dos canais de cromaticidade permite a extração do sinal de rPPG com menor influência de movimentações (YANG et al., 2016). De modo similar, é possível utilizar a subtração ponderada de canais de cor do espaço RGB para reduzir a influência de artefatos de movimento, em conjunto com o rastreamento dos pontos da ROI para eliminar de fato a modulação no sinal de rPPG gerada por esse tipo de ruído (FENG et al., 2014).

Outra implementação demonstra, ainda, que é possível tratar movimentos corporais amplos com o uso de abordagens de detecção contínua do rosto. Somado à isso, a fim de lidar com interferências mais sutis de movimentação, podem ser empregadas técnicas de redundância espacial, em que cada elemento da imagem correspondente a regiões distintas da pele da face é considerado como um sensor independente. Assim, combinar os sinais de rPPG de diferentes entradas de forma a eliminar aqueles que possuem maior influência de artefatos de movimento contribui para otimização da relação sinal-ruído e da acurácia na estimativa da frequência cardíaca (WANG et al., 2014).

Visto isso, a redução da influência da movimentação teve avanços significativos com a utilização de métodos baseados em aprendizado profundo. De fato, a aplicação de

modelos de redes neurais convolucionais é uma estratégia viável para eliminar ruídos de movimento, sobretudo em conjunto com mecanismos de atenção para focar na extração de características específicas do parâmetro fisiológico que se deseja extrair da onda de rPPG (WU et al., 2022a). Um exemplo é a utilização desse tipo de modelo para processar o sinal de cor extraído de tecidos da pele em conjunto com variações de posição da região do nariz para aproximar as movimentações da cabeça como um todo. Nesse caso, as características do espectro de frequência do sinal de movimento extraídas são utilizadas como uma máscara de atenção para gerar o espectro do pulso sem a influência desse sinal (LIU et al., 2021).

2.4.3 Detecção da região de interesse

A extração de sinais de fotopletismografia remota depende intrinsecamente da seleção e detecção de uma região de interesse, na qual são analisadas as variações de cor que são processadas para obtenção da onda de pulso de volume sanguíneo. Dessa forma, a seleção adequada desse parâmetro é essencial para o desenvolvimento de soluções nesse contexto. Nesse raciocínio, a análise de métricas de qualidade do sinal extraído de diferentes regiões da face pelos principais algoritmos de rPPG permite definir áreas que contribuem de modo mais significativo, sendo que pode-se demonstrar que as bochechas e a testa resultam na melhor relação sinal-ruído (KIM et al., 2021; KWON et al., 2015). Da mesma forma, em implementações para estimativa da frequência cardíaca, a utilização de diversas regiões de interesse do rosto combinadas pode aumentar a acurácia, ao passo que a adição excessiva de áreas analisadas aumenta o custo computacional sem otimizar os resultados (BONDARENKO et al., 2025).

Em vista disso, a seleção de uma ROI pode ser realizada de forma fixa e manual (VERKRUYSSSE et al., 2008) ou pode envolver algoritmos de detecção, como o de Viola-Jones (VIOLA; JONES, 2001; VIOLA; JONES, 2004), o qual é comumente aplicado nesse contexto e permite a detecção de objetos em tempo real. No entanto, em cenários que envolvem movimento, a ROI varia de posição ao longo do tempo, fazendo-se necessário seu rastreamento, o que é frequentemente realizado com o algoritmo de Kanade-Lucas-Tomasi (KLT) (TOMASI; KANADE, 1991) para identificação e acompanhamento da posição de pontos de referência. Alternativamente, pode-se aplicar o algoritmo de ajuste de mapas de resposta discriminativos com modelos locais restritos (DRMF, ou *Discriminative Response Map Fitting with Constrained Local Models*) para identificação de pontos e o posterior rastreamento (LIU et al., 2021; LI et al., 2014).

Outras abordagens adotam estratégias de seleção automática em função da contribuição das regiões do rosto para a qualidade do sinal. Assim, a fim de otimizar a relação sinal-ruído, pode ser considerada uma combinação de diferentes regiões de forma ponderada, em função da perfusão e da luz incidente em cada área (KUMAR et al., 2015) ou, ainda, em função da pulsatilidade (BOBBIA et al., 2019). Adicionalmente, há implementações que focam especificamente na intensidade luminosa para selecionar a ROI (BOUSEFSAF et al., 2017). De forma similar, implementações mais recentes focam na seleção dinâmica, com o objetivo de compensar variações causadas por movimento (NAGAR et al., 2024).

2.4.4 Outros fatores

Artefatos de iluminação e de movimento podem ser considerados aspectos externos de interferência na aquisição de sinais de fotopletismografia remota e estão diretamente relacionados à seleção da região de interesse, a qual também impacta na qualidade das informações obtidas. Todavia, a medição de sinais de rPPG também sofre efeito de fatores fisiológicos relacionados sobretudo ao fluxo sanguíneo periférico, que modificam os elementos geradores das variações de volume de sangue, e às propriedades da pele, que alteram a forma com que essas variações são percebidas pelo sensor óptico. Além disso, as características da própria forma de medição referentes às configurações do sensor óptico influenciam na captação do sinal e, portanto, nos resultados das informações extraídas.

No que se refere aos aspectos fisiológicos, fatores como a concentração de hemoglobina, administração de fármacos vasoconstritores ou vasodilatadores, como a nitroglicerina e a noradrenalina, podem influenciar na correlação entre a intensidade do sinal de pulso de volume sanguíneo obtido por câmera e a pressão de pulso obtida pela medição invasiva da pressão arterial de pacientes pós-cirúrgicos (TRUMPP et al., 2017). A influência da hemoglobina se dá devido às suas propriedades ópticas, sendo que, para um fluxo sanguíneo periférico assumidamente constante, quanto maior sua concentração na corrente sanguínea, maior é a absorção de luz e, consequentemente, maior é o caráter pulsátil da variação de intensidade dos pixels capturados por câmera. A administração dos fármacos citados, por sua vez, modifica a dilatação dos vasos periféricos e consequentemente altera a perfusão sanguínea, o que impacta o sinal de pulsação obtido.

Ainda nesse contexto, destaca-se que os sinais ópticos adquiridos por rPPG são afetados pelas características do tecido cutâneo, particularmente a cor da pele determinada sobretudo pela concentração de melanina e comumente caracterizada pela escala Fitzpa-

trick (FITZPATRICK, 1988). Essa influência ocorre devido à maior absorção da luz em tipos de pele mais escuros, de forma que a quantidade de luz refletida e captada pela câmera é menor quando comparada a tipos de pele mais claros, o que resulta na intensidade do sinal também reduzida, sendo que esse fenômeno também é observado na fotopletiografia convencional (FALLOW et al., 2013). Por conseguinte, é possível constatar que a relação sinal-ruído é degradada, bem como as métricas de erro tem piores resultados na aquisição de sinais de indivíduos de pele mais escura (NOWARA et al., 2020) (WANG et al., 2014). Similarmente, a aplicação de maquiagem no rosto também é um fator que impacta o sinal de rPPG de forma negativa devido à redução de sua intensidade relativa (WANG; SHAN, 2020).

À parte isso, o processo de aquisição de imagens é condicionado por diversos parâmetros, de maneira que é fundamental a análise da relação de cada um deles com a aquisição do sinal de interesse. Assim, no que se refere à qualidade do sensor, verifica-se que uma câmera CMOS de alta velocidade pode exibir resultados comparáveis aos de uma webcam simples na estimativa de frequência cardíaca baseada em sinais de rPPG extraídos sob luz ambiente (SUN et al., 2012). Da mesma forma, não há diferenças significativas nos resultados de estimativa de frequência cardíaca a partir de vídeos com alta ou baixa taxa de quadros, especificamente entre 120, 60 e 30 quadros por segundo, bem como a partir de dados com resolução de imagem original ou reduzida a um quarto do valor original, especificamente de 0,32 MP para 0,08 MP (BLACKFORD; ESTEPP, 2015).

Em contrapartida, o controle do tempo de exposição da câmera utilizada para aquisição dos dados pode afetar a relação sinal-ruído (LAURIE et al., 2020). Similarmente, a utilização de algoritmos de compressão pode resultar na perda de características importantes e consequentemente degradar o sinal de forma significativa (MCDUFF et al., 2017; NOWARA; MCDUFF, 2019; YU et al., 2019b). Além disso, a distância entre o indivíduo e a câmera tem influência expressiva dependendo da resolução das imagens capturadas em soluções de rPPG, sendo que, especificamente para distâncias maiores que 1 metro, a captura de vídeos em alta resolução, especialmente em super-alta resolução de 2.7K (2704x1520), contribui para a redução do efeito do ruído de quantização, apesar de aumentar o custo computacional de processamento (SONG et al., 2020a).


2.5 Estimativa de parâmetros fisiológicos

Conforme discutido, a análise das variações de cor captadas por câmera de regiões do tecido cutâneo resulta na onda de pulso de volume sanguíneo característica da fotopleti-


mografia. No entanto, a obtenção de parâmetros fisiológicos significativos no contexto de monitoramento clínico exige o processamento posterior desse sinal. Por isso, mostra-se detalhamento das etapas de estimativa desses parâmetros, o que é apresentado a seguir.

2.5.1 Frequência cardíaca

A frequência cardíaca é o sinal base que se pode obter a partir da onda de rPPG, visto que possui relação direta com a forma de onda do pulso de volume sanguíneo. Assim, é possível realizar a estimativa desse parâmetro no domínio do tempo, por meio do cálculo do intervalo médio entre batimentos obtido pela detecção dos picos do sinal, conforme exemplifica a Figura 3a. Alternativamente, pode-se realizar a análise em frequência, comumente por meio da Transformada Rápida de Fourier, a fim de identificar esse parâmetro no espectro de frequência, como exposto pela Figura 3b (SELVARAJU et al., 2022).



(a) Detecção de picos do sinal de BVP no domínio do tempo



(b) Detecção do pico do espectro de frequência do sinal de BVP

Figura 3: Técnicas de estimativa da frequência cardíaca

Fonte: autoria própria

2.5.2 Variabilidade da frequência cardíaca

A variabilidade da frequência cardíaca (HRV) refere-se à variação do intervalo de tempo entre batimentos cardíacos consecutivos e permite a avaliação da saúde do sistema cardíaco, especialmente do funcionamento do sistema nervoso autônomo responsável por sua regulação (ACHARYA et al., 2006). Esse parâmetro é comumente calculado com base no eletrocardiograma, no entanto pode ser estimado de maneira consistente pela variabilidade da frequência de pulso baseada na onda de PPG para indivíduos em repouso (SCHÄFER; VAGEDDES, 2013). Para isso, analisa-se a variação dos intervalos entre picos ao longo do tempo da onda de pulso de volume sanguíneo.

No contexto da fotopletiografia remota, é demonstrado que a estimativa da frequência cardíaca pode ser obtida com acurácia satisfatória por meio da identificação da frequência predominante do espectro do sinal obtido por câmera. Todavia, a identificação dos intervalos entre batimentos ainda apresenta-se como um desafio. Isso ocorre devido sobretudo à necessidade da detecção precisa de picos do sinal, a qual requer uma relação sinal-ruído adequada que normalmente não é obtida pela medição remota, e devido à necessidade de uma frequência de amostragem mínima para a obtenção de valores de HRV confiáveis, especificamente de 100 Hz no caso da obtenção a partir do eletrocardiograma (MALIK et al., 1996). No caso da obtenção a partir do sinal de PPG, é possível verificar que a Obtenção de medidas de HRV tanto no domínio do tempo quanto no domínio da frequência a partir do sinal de fotopletiografia amostrado a 1000 Hz pode ser comparável a medidas obtidas a partir do sinal amostrado a 50 Hz (PELÁEZ-COCA et al., 2021), valor que, no entanto, não é comumente atingido por câmeras convencionais.

Apesar disso, é possível demonstrar que a interpolação do sinal de rPPG obtido com taxas de quadros menores do que a necessária gera resultados de estimativa de variabilidade da frequência cardíaca próximos aos obtidos com a taxa mínima e com boa correlação quando comparados aos obtidos por sensores de contato (SUN et al., 2013). Ademais, estratégias de otimização da detecção dos picos da onda de BVP medida remotamente contribuem para a obtenção de valores do intervalo entre picos com boa correlação em relação aos valores de referência (MAKI et al., 2019; LI et al., 2020). Analogamente, soluções de aprendizado profundo focadas na redução do ruído dos sinais de crominância capturados por câmera para geração de formas de onda de BVP realistas permitem a otimização da acurácia da estimativa do intervalo entre pulsos e, consequentemente dos parâmetros relacionados à variabilidade de frequência cardíaca (SONG et al., 2021; YANG et al., 2023).

2.5.3 Frequência respiratória

A onda de fotopletiografia reflete a pulsação cardiogênica ao representar as variações temporais no volume sanguíneo periférico, decorrentes da propagação da onda de pulso ao longo do ciclo cardíaco. No entanto, o sinal fotopletiográfico também é influenciado pelo sistema respiratório, de forma que a onda de pulso de volume sanguíneo característica da fotopletiografia também é modulada por três principais fatores relacionados à respiração, conforme exibido na Figura 4. Primeiramente, há uma modulação da linha de base do sinal, induzida pelo retorno venoso causado pelas mudanças na pressão intratorácica que acontecem durante a inspiração e a expiração. Além disso, essas

mudanças de pressão resultam em variações do volume de sangue expelido pelo ventrículo esquerdo, o que gera uma modulação de amplitude da onda. Por fim, há uma modulação da frequência do sinal de PPG gerada pela variação da frequência cardíaca ao longo do ciclo respiratório, em que há a redução do período cardíaco durante a inspiração e um aumento ao longo da expiração devido à atuação do sistema nervoso autônomo, fenômeno denominado arritmia sinusal respiratória. Assim, os efeitos desses fatores podem ser identificados, o que faz com que seja possível extrair informações da respiração pela onda característica de PPG com o uso de algoritmos os quais também podem ser aplicados ao sinal obtido remotamente (LUGUERN et al., 2020).




Figura 4: Tipos de modulação dos sinais de ECG e PPG causados pela respiração

Fonte: Adaptado de Charlton et al. (2016)

No contexto do monitoramento por câmera, duas das principais abordagens envolvem detectar as modulações induzidas pelo ciclo respiratório no sinal de rPPG ou detectar as variações induzidas pelo movimento causado pela respiração (WEI et al., 2017; SCH-RUMPF et al., 2019), sendo que a primeira atinge melhor acurácia e apresenta maior confiabilidade (BOCCIGNONE et al., 2023). De fato, é possível demonstrar que essas modulações podem ser identificadas pela análise das variabilidades da largura, da frequência e da amplitude de pulso (IOZZIA et al., 2017). Mais recentemente, soluções de aprendizado profundo permitem a obtenção de sinais cardíaco e respiratório a partir de modelos multi-tarefas (LEE et al., 2022; LIU et al., 2020).

2.5.4 Saturação periférica de oxigênio (SpO₂)

A saturação periférica de oxigênio (SpO₂) corresponde à razão entre as concentrações da hemoglobina oxigenada e da hemoglobina total presente no sangue, sendo que há

diferenças significativas entre a absorção de luz pela oxihemoglobina e pela desoxihemoglobina ao longo dos diversos comprimentos de onda, de forma proporcional às respectivas concentrações. Assim, a fotopletismografia permite a identificação desse parâmetro por meio da análise da razão entre as amplitudes da componente AC do sinal sob iluminações referentes ao vermelho e ao infravermelho próximo, bem como da componente DC correspondente. A escolha desses comprimentos de onda se dá devido à diferença de absorção das duas substâncias, o que faz com a comparação seja sensível a mudanças na oxigenação (ALLEN, 2007).

Diferente da medição por contato, a estimativa da SpO₂ a partir do sinal obtido remotamente deve levar em consideração a região do espectro luminoso capaz de ser capturada pelo sensor óptico da câmera sob iluminação ambiente. Nesse sentido, as soluções nesse contexto utilizam a comparação entre o vermelho e o verde, considerando as diferenças de absorção pela oxihemoglobina e pela desoxihemoglobina nesses comprimentos de onda (KONG et al., 2013), apesar de a profundidade atingida no tecido cutâneo ser menor na faixa do verde, quando comparada ao infravermelho próximo e ao vermelho (MOÇO; VERKRUYSSSE, 2021). Outras implementações demonstram, ainda, que a utilização dos sinais dos canais azul e vermelho gera resultados comparáveis aos obtidos por um oxímetro de pulso (CASALINO et al., 2020; GS et al., 2024; GUAZZI et al., 2015).

2.5.5 Pressão arterial

A pressão sanguínea refere-se à força que o sangue exerce contra as paredes dos vasos sanguíneos enquanto circula pelo sistema cardiovascular. Esse parâmetro é frequentemente medido de forma invasiva por cateterismo ou de forma não invasiva por ausculta ou método oscilométrico com a utilização de manguitos pressurizados. No entanto, há soluções que estimam esse sinal a partir do tempo de trânsito de onda de pulso (PTT), o qual corresponde ao tempo que a onda de pressão leva para percorrer duas regiões diferentes do sistema arterial. No contexto da fotopletismografia, a medição do PTT pode ser realizada tanto com a comparação entre um eletrodo de ECG com um oxímetro de pulso, quanto por meio da comparação dos sinais de dois oxímetros medidos em locais distintos (MUKKAMALA et al., 2015).

No cenário do monitoramento remoto, por sua vez, o tempo de trânsito de onda de pulso pode ser obtido pela comparação da onda do ECG com o sinal de BVP extraído do rosto (SECERBEGOVIC et al., 2016). Adicionalmente, esse parâmetro pode ser obtido a partir de duas medições remotas realizadas em locais diferentes, como na região do pé

e da mão (MURAKAMI et al., 2015) ou na região do rosto em comparação com a palma da mão (FAN et al., 2020). Por fim, a partir do PTT, a pressão sanguínea é estimada por meio de estratégias de calibração.

Soluções mais recentes, por outro lado, permitem a estimativa da pressão sanguínea remotamente com base na análise unicamente da região do rosto. Para isso, são implementadas estratégias de aprendizado de máquina, por exemplo, para correlacionar esse parâmetro com a distribuição espacial e temporal do sinal de pulso facial utilizando modelos de redes neurais convolucionais (IUCHI et al., 2022) ou uma combinação desse tipo de modelo para extrair características espaciais com redes neurais recorrentes para análise temporal (HAMOUD et al., 2023). É possível, ainda, relacionar a pressão sanguínea com o sinal de rPPG e outros indicadores fisiológicos, como a frequência cardíaca e o tempo de trânsito da onda de pulso, com o uso de redes neurais profundas (WU et al., 2022b).

3 MATERIAIS E MÉTODOS

Este projeto adota um delineamento observacional, prospectivo e analítico, com o objetivo de validar algoritmos de rPPG para extração de sinais fisiológicos em pacientes críticos internados na UTI do Hospital Universitário da Universidade de São Paulo. O estudo foi aprovado pelo Comitê de Ética em Pesquisa da instituição sob o número Certificado de Apresentação de Apreciação Ética (CAAE) 86650625.3.0000.0076. Todos os dados foram coletados com permissão explícita dos indivíduos envolvidos ou de seus representantes, de modo que as coletas ocorreram apenas após a leitura e assinatura do Termo de Consentimento Livre e Esclarecido (TCLE) pelo participante ou seu representante legal.

3.1 Aquisição de dados

A aquisição de dados foi realizada em dois experimentos diferentes, denominados Coleta 1 e Coleta 2. Em etapas futuras, serão realizadas outras coletas de dados distribuídas durante o período de desenvolvimento deste trabalho.

3.1.1 Coleta 1

O primeiro experimento realizado, denominado Coleta 1, se deu por meio da aquisição de vídeos da face de pacientes internados na UTI, sob condições de iluminação ambiente do leito, sem interferência na conduta clínica e sem imposição de restrições ao paciente durante o período de monitoramento. Inicialmente, após a inclusão do participante no estudo, foi definida a posição de monitoramento de acordo com a condição do paciente no momento da coleta. Quando o paciente estava deitado no leito, a câmera foi posicionada ao pé da cama hospitalar, conforme ilustrado na Figura 5. Quando o paciente estava sentado na poltrona disponível no ambiente de internação, a câmera foi posicionada a uma distância fixa aproximada de 180 cm da face.



Figura 5: Figura 5: Esquemático do ambiente de coleta de dados em UTI, ilustrando a aquisição simultânea de vídeos faciais por câmera e de sinais fisiológicos de referência obtidos do monitor multiparâmetros à beira-leito.

Fonte: autoria própria

Antes de cada gravação, foram registradas as condições de iluminação próximas à face do paciente por meio de um luxímetro digital (Fluke 941, Fluke Corporation, EUA). Também foi realizada a estimativa do fototipo cutâneo, de acordo com a escala de Fitzpatrick, utilizando um Analisador de Fototipo de Pele Digital (*Skinup Beauty Devices*, Brasil), posicionado na região da testa. Após esse registro, foi realizada a gravação de vídeo da face do paciente, com duração aproximada de dois minutos, com uma câmera industrial do modelo VCXG.2-57C (Baumer, Suíça) com comunicação Ethernet configurada com taxa de 25 quadros por segundo e formato de pixel BGR8. Para cada paciente, o tempo de exposição, ganho, foco e abertura do sensor foram configurados de forma a maximizar a qualidade visual das imagens, reduzindo regiões de baixa iluminância causadas por subexposição e evitando saturação de pixels, considerando, ademais, que o aumento do tempo de exposição é limitado pelo intervalo temporal entre quadros definido pela taxa de aquisição. A resolução, por sua vez, foi definida de forma a enquadrar o rosto e parte do tórax e os vídeos são capturados em formato AVI sem compressão. Durante essa etapa, foram mantidas as condições naturais de monitoramento da UTI, incluindo eventuais movimentos espontâneos do paciente, variações de iluminação ambiente e interferências comuns ao cenário clínico real.

Simultaneamente à gravação do vídeo, foram adquiridos sinais fisiológicos de referência a partir dos monitores multiparâmetros (BSM-3000 Series, Nihon Kohden, Japão), já instalados à beira-leito. Foram coletados o sinal de eletrocardiograma, com taxa de amostragem de 250 Hz, o sinal respiratório ou parâmetro de frequência respiratória, com taxa de amostragem de 125 Hz e a onda de fotopletismografia obtida pelo oxímetro de pulso, com taxa de amostragem de 62,5 Hz. Esses sinais foram obtidos por meio de um sistema de coleta previamente implementado para comunicação direta com os monitores

multiparâmetros.

No que se refere à sincronização dos dados de vídeo com os sinais de referência, foram utilizadas duas estratégias. A primeira considerou a análise por correlação entre as estimativas de frequência cardíaca obtidas a partir do sinal de rPPG e das obtidas por meio do ECG adquirido de forma contínua, de forma que o ponto de maior correlação foi considerado para o alinhamento temporal desses sinais. A segunda estratégia foi baseada na inserção de um ruído no eletrocardiograma por meio de uma interferência física em um dos eletrodos visível no enquadramento do vídeo.

3.1.2 Coleta 2

O segundo experimento realizado, denominado Coleta 2, se deu por meio da gravação de vídeos da face de um indivíduo saudável não hospitalizado para a validação do *setup* experimental. Antes de cada gravação, foram registradas as condições de iluminação próximas à face do paciente por meio de um luxímetro digital (Fluke 941, Fluke Corporation, EUA). Também foi realizada a estimativa do fototipo cutâneo, de acordo com a escala de Fitzpatrick, utilizando um Analisador de Fototipo de Pele Digital (*Skinup Beauty Devices*, Brasil), posicionado na região da testa.

Em seguida, foi realizada a aquisição de dois vídeos em formato AVI sem compressão de 2 minutos e 5 segundos de duração, com uma câmera industrial do modelo VCXU.2-57C (Baumer, Suíça) com comunicação USB 3.0 configurada com 50 quadros por segundo, com uma resolução fixa de 1056x1076 e tempo de exposição fixo em 19500 milissegundos. O ganho, foco e abertura do sensor foram configurados de forma a maximizar a qualidade visual das imagens, reduzindo regiões de baixa iluminância causadas por subexposição e evitando saturação de pixels. Além disso, a distância entre o indivíduo e a câmera foi definida como 140 centímetros. Nesse caso, foi adquirido o sinal de eletrocardiograma, correspondente à derivação II, com um equipamento de eletromiografia e registro de potenciais evocados (MEB-2300K, Nihon Kodan, Japão) com frequência de amostragem de 1000 Hz. A sincronização de dados foi realizada por meio do alinhamento temporal baseado na inserção de um ruído no eletrocardiograma por meio de uma interferência física em um dos eletrodos visível no enquadramento do vídeo.

3.1.3 Coletas futuras

Em etapas futuras, serão realizadas outras coletas de dados no ambiente da UTI, distribuídas em diferentes momentos de forma a considerar condições de iluminação distintas, tanto no período diurno, quanto no período noturno. Essas coletas se darão por meio da gravação de vídeos da face de pacientes, bem como da aquisição dos sinais de referência dos monitores multiparâmetros. Antes de cada gravação, serão registradas as condições de iluminação próximas à face do paciente por meio de um luxímetro digital (Fluke 941, Fluke Corporation, EUA). Também será realizada a estimativa do fototipo cutâneo, de acordo com a escala de Fitzpatrick, utilizando um Analisador de Fototipo de Pele Digital (*Skinup Beauty Devices*, Brasil), posicionado na região da testa.

Para cada paciente, serão adquiridos dois vídeos em formato AVI sem compressão de 2 minutos e 5 segundos de duração, com uma câmera do modelo VCXU.2-57C (Baumer, Suíça) com comunicação USB 3.0 configurada com 50 quadros por segundo, com uma resolução fixa de 1056x1076 e tempo de exposição fixo em 19500 milissegundos. O ganho, foco e abertura do sensor foram configurados de forma a maximizar a qualidade visual das imagens, reduzindo regiões de baixa iluminância causadas por subexposição e evitando saturação de pixels. Além disso, a distância entre o indivíduo e a câmera será definida de acordo com a posição do paciente no ambiente de internação. Caso o paciente esteja deitado no leito, a câmera será posicionada ao pé da cama hospitalar. Caso o paciente esteja sentado na poltrona disponível no ambiente, a câmera será posicionada a uma distância fixa de 180 cm da face.

Simultaneamente à gravação de cada vídeo, serão adquiridos sinais fisiológicos de referência a partir dos monitores multiparamétricos (BSM-3000 Series, Nihon Kohden, Japão), já instalados à beira-leito. Serão coletados o sinal de eletrocardiograma, com taxa de amostragem de 250 Hz, o sinal respiratório, com taxa de amostragem de 125 Hz e a onda de fotopletismografia obtida pelo oxímetro de pulso, com taxa de amostragem de 62,5 Hz. A sincronização de dados será realizada por meio do alinhamento temporal baseado na inserção de um ruído no eletrocardiograma por meio de uma interferência física em um dos eletrodos visível no enquadramento do vídeo.

3.2 Processamento de dados de vídeo

Os dados de vídeo foram processados com o uso do conjunto de ferramentas de código aberto denominado rPPG-Toolbox (LIU et al., 2022), o qual disponibiliza implementações

dos principais métodos não supervisionados de extração de sinais por fotopletismografia remota. Além disso, esse recurso inclui modelos supervisionados para treinamento e teste em bases de dados de acesso livre, além de permitir a inclusão de modelos e bases customizados. Com isso, propõe-se a validação dos algoritmos mostrados na Tabela 1 nos dados coletados dos pacientes de UTI, por meio da inserção de um dataset customizado e da adaptação do conjunto de ferramentas citado.

Tabela 1: Métodos a serem validados nos dados coletados


Tipo	Método	Estratégia
Não supervisionado	GREEN (VERKRUYSSSE et al., 2008)	Análise do canal verde
	ICA (POH et al., 2010a)	Separação cega de sinais
	CHROM (HAAN; JEANNE, 2013)	Modelo baseado em crominância
	PBV (HAAN; LEEST, 2014)	Modelo do vetor de pulso
	POS (WANG et al., 2016)	Projeção no subespaço ortogonal ao tom de pele
	LGI (PILZ et al., 2018)	Modelagem de variações espaciais para robustez a movimento
	OMIT (CASADO; LÓPEZ, 2023)	Modelagem baseada em decomposição de matrizes
Supervisionado	DeepPhys (CHEN; MCDUFF, 2018)	CNN 2D com mecanismo de atenção
	TSCAN (LIU et al., 2020)	CNN 2D com módulos de deslocamento temporal
	PhysNet (YU et al., 2019a)	CNN 3D
	PhysFormer (YU et al., 2022)	Transformer Visual
	EfficientPhys (LIU et al., 2023)	Swin Transformer

Em cada vídeo de entrada, foi realizada a detecção da face utilizando a ferramenta YOLO5Face (QI et al., 2022) a cada 25 quadros, sendo que a região de interesse selecionada foi a região retangular retornada por essa ferramenta. Em seguida, os quadros recortados nessa região foram utilizados como entrada para os algoritmos de rPPG. No caso especificamente dos algoritmos não supervisionados, foi realizada, ainda, a média espacial dos pixels de cada quadro para o processamento das variações das intensidades dos canais de cor. Em relação à validação dos métodos baseados em aprendizado profundo, foram considerados os modelos treinados no dataset denominado PURE (STRICKER et al., 2014) e no dataset referido como UBFC-rPPG (BOBBIA et al., 2019).


A partir da onda de pulso resultante dos algoritmos considerados, a frequência cardíaca foi estimada por análise em frequência utilizando a FFT em janelas de 15 segundos, sendo que o pico do espectro de potência do sinal filtrado por um filtro passa-banda

entre as bandas de 0,6 e 3,3 Hz foi considerado como a frequência cardíaca. A frequência respiratória foi estimada por meio da extração de três modulações do sinal de rPPG causadas pela respiração, sendo elas a modulação de linha de base (BW), a modulação de amplitude (AM) e a modulação de frequência (FM). Para isso, o sinal inicial extraído com cada um dos algoritmos de rPPG definidos foi filtrado por um filtro passa-altas com frequência de corte correspondente a 4 respirações por minuto.


A partir do sinal inicial de rPPG, a demodulação da componente BW foi obtida por meio da sequência discreta formada pela média entre as amplitudes dos pontos de vale e dos respectivos picos subsequentes, conforme exemplifica a Figura 6a. A demodulação de amplitude foi obtida por meio da sequência discreta formada pelas diferenças entre as amplitudes dos pontos de vale e dos respectivos picos subsequentes, conforme exemplifica a Figura 6b. A demodulação da componente FM, por sua vez, foi obtida pela sequência discreta formada pelos intervalos entre picos consecutivos, como explicitado pela Figura 6c.



(a) Demodulação da componente BW



(b) Demodulação da componente AM



(c) Demodulação da componente FM

Figura 6: Estratégias de extração de cada modulação gerada pela respiração a partir do sinal de rPPG

Assim, as sequências discretas referentes às demodulações de amplitude e de linha de base foram re-amostradas em uma grade temporal uniforme de 4 Hz por meio de interpolação linear. Já a sequência referente à demodulação de frequência foi re-amostrada em uma grade temporal uniforme de 4 Hz por meio do algoritmo de Berger (BERGER et al., 1986). A partir disso, a frequência respiratória foi estimada a partir de cada uma das sequências interpoladas por meio de análise espectral, de forma que a frequência com maior energia no espectro de potência obtido por FFT dentro das bandas esperadas nesse contexto, de 4 a 65 respirações por minuto, foi considerada como o valor de frequência respiratória obtido a partir da demodulação correspondente. Esse processo foi realizado em janelas de 30 segundos do sinal de rPPG original. Em seguida, a fim de reduzir interferências de artefatos de ruído, foi realizada uma estratégia de fusão das estimativas de frequência respiratória realizadas a partir das três demodulações, de modo que foi considerada como estimativa final a média desses 3 valores (CHARLTON et al., 2016; LUGUERN et al., 2020).

3.3 Processamento dos dados de referência

No que se refere ao processamento dos dados de referência, foi extraído o sinal do eletrocardiograma considerado como padrão-ouro para a obtenção da frequência cardíaca, sendo que esse parâmetro foi calculado utilizando a biblioteca HeartPy (GENT et al., 2018), considerando janelas de 15 segundos. A forma de onda fotopletismográfica, por sua vez, obtida com um oxímetro de pulso posicionado no dedo indicador, foi utilizada para comparação com o sinal de pulso resultante dos algoritmos por meio de uma análise por correlação cruzada baseada no índice de correlação de Pearson. Por fim, a frequência respiratória de referência foi calculada por análise em frequência do sinal respiratório de referência, por meio da aplicação da FFT em janelas de 30 segundos, de modo que o pico do espectro de potência considerado entre 4 e 65 respirações por minuto foi considerado como o valor da frequência respiratória de referência.

3.4 Métricas de avaliação

Para avaliação das estimativas de frequência cardíaca e frequência respiratória obtidas remotamente, foram calculados o Erro Absoluto Médio (*Mean Absolute Error* - MAE), o Erro Quadrático Médio (*Root Mean Square Error* - RMSE) e o Erro Percentual Absoluto Médio (*Mean Absolute Percentage Error* - MAPE), de forma que os valores de frequência

cardíaca estimados a partir do sinal de rPPG foram comparados janela a janela com os valores estimados a partir do ECG. Os valores de frequência respiratória estimados a partir do sinal obtido remotamente, por sua vez, foram comparados janela a janela com os valores estimados a partir do sinal respiratório de referência. Ademais, foi calculada a relação sinal-ruído da onda de rPPG, considerando a frequência cardíaca obtida por meio do ECG como referência. Também foi calculado o Índice de Correlação de Pearson para comparação entre a onda de rPPG e a onda fotopletismográfica obtida com o oxímetro de pulso. Nesse sentido, é definido a seguir o cálculo de cada métrica aplicada.

Erro Absoluto Médio (MAE)

$$MAE = \frac{1}{N} \sum_{n=1}^N |R_g - R_p| \quad (3.1)$$

Erro Quadrático Médio (RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{n=1}^N (R_g - R_p)^2} \quad (3.2)$$

Erro Percentual Absoluto Médio (MAPE)

$$MAPE = \frac{1}{N} \sum_{n=1}^N \left| \frac{R_g - R_p}{R_g} \right| \quad (3.3)$$

Índice de Correlação de Pearson (ρ)

$$\rho = \frac{\sum_{n=1}^N (R_{g,n} - \bar{R}_g)(R_{p,n} - \bar{R}_p)}{\sqrt{\left(\sum_{n=1}^N (R_{g,n} - \bar{R}_g)^2\right) \left(\sum_{n=1}^N (R_{p,n} - \bar{R}_p)^2\right)}} \quad (3.4)$$

Em todas as equações, R_g é o valor de referência, R_p é o valor estimado por meio do sinal obtido remotamente, N é o número de amostras de janelas considerado e $\bar{R}_g$ e $\bar{R}_p$ são as médias desses valores ao longo das amostras.

Relação Sinal-Ruído (SNR)

A relação sinal-ruído é obtida pela razão entre a energia espectral associada à frequência fundamental do sinal de referência e ao seu primeiro harmônico e a energia espectral remanescente considerando a banda de busca entre 36 bpm e 198 bpm, ou 0,6 Hz e 3,3 Hz, de acordo com a equação:

$$SNR = 10 \log_{10} \left(\frac{\sum_{f=36}^{198} (U_t(f)S(f))^2}{\sum_{f=36}^{198} ((1 - U_t(f))S(f))^2} \right) \quad (3.5)$$

Nesse caso, S é o espectro de frequência do sinal de rPPG, f é a frequência em batimentos por minuto e $U_t(f)$ representa uma máscara binária centrada na frequência fundamental e no primeiro harmônico do sinal de referência. Essa máscara foi considerada de forma a assumir valor unitário nas bandas de interesse delimitadas por uma tolerância de $\pm 0,1$ Hz em torno dessas frequências e valor nulo nas demais componentes espectrais, conforme exemplifica a Figura 7.




Figura 7: Representação da máscara espectral empregada no cálculo da relação sinal-ruído (SNR). As regiões destacadas em verde e amarelo correspondem, respectivamente, às bandas centradas na frequência fundamental do sinal de referência e em seu primeiro harmônico, considerando uma tolerância de $\pm 0,1$ Hz. A energia contida nessas bandas é considerada como sinal, enquanto a energia espectral remanescente na banda de análise é considerada como ruído.

Fonte: autoria própria

3.5 Construção da base de dados pública

Serão disponibilizados os vídeos e os sinais de referência adquiridos de modo anonimizado em forma de uma base de dados pública, a fim de fomentar desenvolvimentos futuros de aplicações de fotopletismografia remota baseadas em dados de condições clínicas reais. Para isso, cada vídeo será anonimizado por meio da inserção de uma máscara sobre os olhos e a boca dos pacientes em cada quadro. Para que esse procedimento de anonimização não prejudique a detecção de regiões de interesse, será disponibilizada uma malha com as estimativas de 478 pontos da face em cada quadro do vídeo gerada com o modelo de malha facial (KARTYNNIK et al., 2019) da biblioteca MediaPipe (LUGARESI et al.,

2019). Além disso, será disponibilizada uma versão simplificada da detecção da face que corresponde à região retangular gerada com a ferramenta Yolo5Face (QI et al., 2022). Em relação aos sinais de referência, serão disponibilizados os sinais referentes ao ECG, ao sinal respiratório e à onda de fotopletismografia obtida com oxímetro de pulso respectivos a cada vídeo.

4 RESULTADOS PRELIMINARES

4.1 Coleta 1

Na coleta 1, foram adquiridos vídeos e os sinais correspondentes provenientes de monitores multiparâmetros de três pacientes admitidos na UTI. Em um dos casos, o oxímetro de pulso não estava conectado no momento da aquisição, impossibilitando a obtenção do sinal de fotopletismografia de referência. Entre os dois pacientes restantes, um encontrava-se sob suporte ventilatório mecânico e sedação, enquanto o outro estava em estado ativo e sem suporte ventilatório. A seguir, são expostos os resultados do processamento dos sinais obtidos.

4.1.1 Sincronização de dados

Para realizar a sincronização dos vídeos com os dados de referência, foi realizada uma análise de correlação baseada no índice de correlação de Pearson entre estimativas de frequência cardíaca realizadas a partir do eletrocardiograma e as estimativas realizadas a partir do sinal de rPPG extraído por cada um dos métodos não supervisionados citados na Tabela 1, conforme exemplifica a Figura 8. Com isso, foi obtido o gráfico de correlação média entre todos os métodos para cada paciente, como pode ser observado no exemplo da Figura 9. A partir do ponto de maior correlação em cada caso, foi obtido o intervalo a ser considerado para a extração dos dados de referência.

Para o paciente 3, foi realizada a sincronização por meio da geração de um ruído no eletrocardiograma causado pela desconexão e reconexão de um dos eletrodos. Foi possível visualizar o momento de geração desse ruído por um pico na forma de onda do ECG, a qual é apresentada na Figura 10.




Figura 8: Etapas de definição do intervalo considerado para os dados de referência do paciente 2

Fonte: autoria própria




Figura 9: Correlação média entre os valores de frequência cardíaca obtidos a partir do ECG de referência e os valores estimados pelos métodos de rPPG para o paciente 2

Fonte: autoria própria




Figura 10: Ruído gerado no eletrocardiograma do paciente 3 para sincronização dos dados de referência com o vídeo.

Fonte: autoria própria.

4.1.2 Sinal de rPPG

A correlação entre os sinais de rPPG e os sinais de fotopletismografia de referência dos vídeos da Coleta 1 foi analisada pelos respectivos índices de correlação de Pearson. Os valores resultantes para os pacientes 1 e 2 são apresentados na Tabela 2, em que os termos entre parênteses representam as bases de dados nas quais foram treinados cada modelo.

Tabela 2: Índices de correlação entre os sinais de rPPG e o sinal de PPG de referência para os pacientes 1 e 2.

Categoria	Método	Paciente 1	Paciente 2
Não supervisionado	CHROM	0.0991	0.5754
	GREEN	0.3323	0.1350
	ICA	0.1114	0.6783
	LGI	0.1305	0.3575
	OMIT	0.1336	0.3629
	PBV	0.1252	0.5288
	POS	0.1184	0.6884
Supervisionado	DeepPhys (PURE)	0.1070	0.4276
	DeepPhys (UBFC)	0.1061	0.4992
	EfficientPhys (PURE)	0.0944	0.4576
	EfficientPhys (UBFC)	0.0949	0.4342
	PhysFormer (PURE)	0.0740	0.4547
	PhysFormer (UBFC)	0.0602	0.4141
	PhysNet (UBFC)	0.0636	0.3151
	PhysNet (PURE)	0.0425	0.4367
	TSCAN (PURE)	0.1309	0.5650
	TSCAN (UBFC)	0.1430	0.4505

Os sinais de rPPG que resultaram no maior coeficiente de correlação entre os métodos supervisionados foram gerados pelo modelo TSCAN treinado no dataset UBFC-rPPG para o paciente 1 e pelo modelo TSCAN treinado no dataset PURE para o paciente 2. Os sinais obtidos por métodos não supervisionados, por sua vez, que resultaram no maior coeficiente de correlação foram obtidos pelo método GREEN para o paciente 1 e pelo método POS para o paciente 2, sendo que esses sinais em comparação com a referência são apresentados na Figura 11. Reitera-se que essa análise não foi realizada para o paciente 3 devido à ausência do sinal de PPG de referência durante a coleta de dados.

4.1.3 Estimativas de frequência cardíaca

O erro médio absoluto, o erro médio quadrático em batimentos por minuto e o erro médio percentual entre as estimativas de frequência cardíaca obtidas a partir dos sinais gerados por cada método de rPPG e as obtidas pelo ECG referentes aos pacientes 1, 2 e 3 são exibidos na Tabela 3.




Figura 11: Sinais de rPPG dos métodos que obtiveram o maior coeficiente de correlação de Pearson com o sinal de PPG de referência em cada paciente, considerando o alinhamento temporal realizado por meio de correlação cruzada.

Fonte: autoria própria.

É possível observar que o método não supervisionado que resultou no menor valor de erro absoluto médio para o paciente 1 foi o método CHROM. Em relação ao sinal do paciente 2, os métodos CHROM, ICA e POS resultaram nos menores valores de erro comparados ao restante dos métodos. Além disso, os métodos LGI e POS foram os que resultaram nos menores valores de erro para as estimativas de frequência cardíaca a partir dos sinais do paciente 3. No que se refere aos métodos supervisionados, por sua vez, o modelo PhysFormer treinado do dataset PURE foi o que apresentou o melhor resultado para o paciente 1, o modelo TSCAN treinado no dataset PURE resultou no menor valor de erro para as estimativas do paciente 2 e o modelo PhysNet treinado no mesmo dataset foi o que obteve o melhor resultado para o paciente 3. À parte isso, a comparação entre todos os métodos permite analisar que o método POS foi o que resultou na melhor relação sinal-ruído para os sinais dos pacientes 2 e 3. Já para o paciente 1, o sinal gerado pelo modelo PhysFormer treinado na base de dados PURE foi o que apresentou o melhor valor para essa métrica.

Observa-se, por fim, que os métodos CHROM, ICA e POS aplicados ao sinal do paciente 2 resultaram no menor valor de erro absoluto médio entre todos os algoritmos não supervisionados. Da mesma forma, o modelo TSCAN treinado no dataset PURE também aplicado ao sinal do paciente 2 resultou no menor erro absoluto médio entre

Tabela 3: Métricas de erro da estimativa de frequência cardíaca por meio de cada método de rPPG em comparação com as realizadas a partir do ECG para os pacientes 1, 2 e 3.

Categoria	Método	Paciente 1				Paciente 2				Paciente 3			
		MAE	RMSE	MAPE	SNR	MAE	RMSE	MAPE	SNR	MAE	RMSE	MAPE	SNR
Não supervisionado	CHROM	16.93	19.37	16.12	-9.80	0.89	1.06	1.15	0.14	3.65	6.34	4.22	0.07
	GREEN	25.89	26.13	24.75	-9.40	11.60	14.99	14.93	-8.39	24.60	27.50	27.02	-10.80
	ICA	39.70	41.61	38.24	-11.06	0.89	1.06	1.15	2.66	18.56	21.59	20.30	-7.68
	LGI	26.31	26.50	25.15	-9.52	4.06	5.49	5.20	-3.92	2.59	4.99	3.02	-2.51
	OMIT	26.31	26.50	25.15	-9.54	4.06	5.49	5.20	-3.79	4.49	7.99	5.11	-4.03
	PBV	26.31	26.50	25.15	-9.53	1.29	1.51	1.67	-0.45	2.80	5.05	3.25	-1.41
	POS	28.82	34.73	27.83	-9.74	0.89	1.06	1.15	2.83	2.59	4.99	3.02	1.51
Supervisionado	PhysFormer (PURE)	16.97	26.69	16.43	-6.07	5.68	9.53	7.21	-3.85	8.25	15.92	9.08	-2.56
	PhysFormer (UBFC)	40.54	41.43	38.67	-7.96	3.09	5.87	3.91	-2.61	8.53	14.37	9.42	-1.96
	EfficientPhys (PURE)	45.47	46.69	43.43	-10.40	6.44	10.87	8.18	-3.10	6.82	13.82	7.52	-0.87
	EfficientPhys (UBFC)	48.49	49.84	46.33	-8.49	8.27	12.05	10.52	-3.72	6.82	13.82	7.52	-1.61
	PhysNet (PURE)	33.15	36.16	31.72	-11.06	5.09	8.34	6.61	-2.80	1.20	1.87	1.38	-1.66
	PhysNet (UBFC)	26.20	29.30	25.10	-8.59	7.78	11.48	9.89	-6.01	17.86	23.15	19.59	-5.36
	TSCAN (PURE)	50.16	53.07	47.87	-8.56	1.42	2.05	1.82	-1.25	17.62	24.35	19.47	-4.96
	TSCAN (UBFC)	33.15	36.16	31.72	-9.69	3.93	8.05	4.96	-2.87	16.61	22.73	18.59	-3.96
	DeepPhys (PURE)	51.00	51.35	48.77	-11.68	13.56	19.26	17.37	-3.50	29.52	34.72	32.99	-6.25
	DeepPhys (UBFC)	50.16	51.83	47.81	-10.24	10.79	16.05	13.74	-2.71	18.72	25.62	21.06	-3.07

os modelos supervisionados. Na Figura 12, pode-se analisar os espectrogramas de dois desses sinais, nos quais é possível identificar, de forma distinguível, uma região de maior densidade espectral de potência persistente ao longo da maior parte da janela temporal analisada.

Similarmente, os espectros de potência desses sinais apresentados na Figura 13 permitem a identificação do pico referente à essa frequência, a partir da qual pode ser realizada a estimativa do valor de frequência cardíaca. Nesse caso, a análise em frequência foi realizada no sinal completo com duração próxima a dois minutos. Em comparação, as estimativas de frequência cardíaca por janela são apresentadas na Figura 14.




Figura 12: Espectrogramas de dois dos sinais de rPPG cujas estimativas de frequência cardíaca resultaram no menor erro absoluto médio em relação às estimativas obtidas por meio do ECG.

Fonte: autoria própria

Ademais, é possível observar o erro absoluto médio entre todos os métodos não supervisionados em comparação com os métodos supervisionados em cada janela para os pacientes 1 e 2 na Figura 15. Verifica-se que, para cada paciente, os dois tipos de métodos possuem alguns picos de erro em comum, a exemplo da janela 5 do sinal do paciente 2,




Figura 13: Espectros de potência de dois dos sinais de rPPG cujas estimativas de frequência cardíaca resultaram no menor erro absoluto médio em relação às estimativas obtidas por meio do ECG

Fonte: autoria própria




Figura 14: Estimativas de frequência cardíaca por janela obtidas por meio de dois dos métodos de rPPG que resultaram no menor erro absoluto médio em relação às estimativas obtidas por meio do ECG

Fonte: autoria própria

que representa o maior erro para ambos os tipos de algoritmo. De forma análoga, a janela de índice zero desse sinal é a que resulta no menor erro absoluto médio para os dois tipos de método.




Figura 15: Erro absoluto médio por janela das estimativas de frequência cardíaca realizadas a partir dos métodos supervisionados e não supervisionados para os pacientes 2 e 3.

Fonte: autoria própria

4.1.4 Estimativas de frequência respiratória

O erro médio absoluto em batimentos por minuto, o erro médio quadrático e o erro médio percentual entre as estimativas de frequência respiratória obtidas a partir dos sinais gerados por cada método de rPPG e as obtidas pelo sinal de referência para os pacientes 1, 2 e 3 são exibidos na Tabela 4.

Tabela 4: Métricas de erro da estimativa de frequência respiratória por meio de cada método de rPPG em comparação com as obtidas a partir do sinal de referência para os pacientes 1, 2 e 3.

Categoria	Método	Paciente 1			Paciente 2			Paciente 3		
		MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
Não supervisionado	CHROM	10.53	11.21	41.08	7.04	7.76	32.51	8.64	10.41	66.66
	GREEN	12.77	13.21	49.82	11.57	11.84	54.25	5.72	7.54	26.09
	ICA	10.37	11.20	40.47	5.33	5.95	24.54	2.79	2.97	20.29
	LGI	12.09	12.25	47.17	6.31	6.48	29.43	9.36	9.48	64.38
	OMIT	12.77	12.97	49.82	7.61	7.92	36.00	11.02	12.10	81.79
	PBV	12.72	12.86	49.61	4.65	6.05	21.40	12.27	12.32	80.51
	POS	9.38	9.89	36.61	5.28	5.37	24.67	8.42	9.25	44.87
Supervisionado	DeepPhys (PURE)	10.58	11.72	41.28	4.90	5.31	22.60	6.96	8.32	35.99
	DeepPhys (UBFC)	12.46	12.98	48.60	2.13	2.24	10.06	7.48	7.61	47.60
	EfficientPhys (PURE)	13.81	13.89	53.88	1.30	1.84	6.33	10.51	10.82	78.09
	EfficientPhys (UBFC)	8.13	8.40	31.73	5.42	6.70	24.77	4.94	7.15	24.64
	PhysFormer (PURE)	11.00	11.21	42.91	1.26	2.04	5.75	10.56	11.47	75.31
	PhysFormer (UBFC)	11.57	11.93	45.14	6.94	8.50	31.61	7.64	8.36	58.11
	PhysNet (PURE)	7.29	8.51	28.46	5.58	6.50	26.73	11.13	13.69	98.42
	PhysNet (UBFC)	9.38	10.66	36.61	7.31	8.83	33.57	7.33	7.41	51.77
	TSCAN (PURE)	11.52	11.64	44.94	10.41	11.00	48.22	9.20	10.73	68.56
	TSCAN (UBFC)	8.92	10.02	34.78	10.58	11.74	48.84	3.52	3.85	26.50

4.2 Coleta 2

Na coleta 2, foram extraídos dois vídeos de um indivíduo saudável e os sinais de eletrocardiograma correspondentes. No primeiro vídeo coletado, o indivíduo apresentou pouca movimentação, enquanto no vídeo subsequente houve maior movimentação do rosto causada por fala, riso e rotações sutis da cabeça.

4.2.1 Sincronização dos dados

A sincronização entre os dados de vídeo e o sinal de referência foi realizada por meio da geração de um ruído no ECG devido a um impacto no eletrodo utilizado. Foi possível visualizar essa interferência de forma distinguível, conforme demonstra a Figura 16.




Figura 16: Visualização do instante em que foi gerado o ruído no eletrocardiograma para sincronização de dados da Coleta 2

Fonte: autoria própria

4.2.2 Estimativas de frequência cardíaca

A partir dos sinais de pulso de volume sanguíneo obtidos por meio de cada um dos métodos e modelos de fotopletismografia remota aplicados aos dois vídeos adquiridos durante a coleta 2, foram realizadas as estimativas de frequência cardíaca. Essas estimativas foram comparadas com as obtidas a partir do ECG e os resultados são dispostos na Tabela 5.

Tabela 5: Métricas de erro das estimativas de frequência cardíaca por meio de cada método de rPPG em comparação com as realizadas a partir do ECG para os vídeos 1 e 2.

Categoria	Método	Vídeo 1				Vídeo 2			
		MAE	RMSE	MAPE	SNR	MAE	RMSE	MAPE	SNR
Não supervisionado	CHROM	3.11	4.67	4.23	0.71	7.30	8.42	9.05	-5.40
	GREEN	8.85	11.73	12.18	-6.40	7.59	9.03	9.71	-8.42
	ICA	1.69	2.25	2.32	4.74	10.94	12.55	13.81	-7.06
	LGI	1.86	2.35	2.56	0.39	5.86	7.39	7.40	-6.81
	OMIT	1.86	2.35	2.56	0.21	5.86	7.39	7.40	-6.75
	PBV	2.03	2.46	2.79	-2.44	6.98	7.74	8.63	-7.94
	POS	1.86	2.35	2.56	1.49	9.97	12.77	12.52	-5.84
Supervisionado	PhysFormer (PURE)	2.34	3.43	3.23	-3.66	12.67	16.13	15.56	-5.62
	PhysFormer (UBFC)	57.39	59.45	79.59	-5.64	32.36	36.73	41.80	-7.68
	EfficientPhys (PURE)	1.69	2.25	2.32	-0.96	10.40	12.81	12.68	-7.59
	EfficientPhys (UBFC)	5.58	8.14	7.71	-2.99	11.58	14.86	14.16	-6.23
	PhysNet (PURE)	5.08	9.01	7.00	-2.33	11.09	16.73	13.90	-6.40
	PhysNet (UBFC)	40.79	43.55	56.31	-8.38	39.06	40.00	50.00	-9.31
	TSCAN (PURE)	3.64	4.96	5.02	-2.71	11.09	15.57	13.42	-6.47
	TSCAN (UBFC)	13.29	20.32	18.13	-6.05	24.31	26.52	30.95	-7.56
	DeepPhys (PURE)	13.27	16.11	18.39	-5.56	18.68	20.76	23.77	-7.10
	DeepPhys (UBFC)	9.49	11.02	13.01	-6.09	16.01	20.10	20.28	-6.70

Pode-se verificar que, entre os métodos não supervisionados, o método ICA foi o que resultou em estimativas de frequência cardíaca com o menor erro médio absoluto para o vídeo 1 e os métodos LGI e OMIT resultaram no menor erro para o vídeo 2. Em relação aos modelos supervisionados, o modelo EfficientPhys treinado na base de dados PURE foi o que apresentou o menor erro médio absoluto em ambos os vídeos. Ademais, o método ICA foi o que resultou, entre todos os métodos, no melhor valor de SNR para o vídeo 1,

enquanto o método CHROM foi o que gerou o melhor valor para o vídeo 2.

Por fim, entre todos os métodos avaliados em ambos os vídeos, o método ICA e o modelo EfficientPhys treinado na base PURE aplicados ao sinal do vídeo 1 foram os que apresentaram os menores valores de erro médio absoluto. Os espectrogramas referentes aos sinais resultantes desses algoritmos são apresentados na Figura 17, bem como seus respectivos espectros de potência na Figura 18. A partir das figuras, observa-se que a frequência com maior densidade de potência pode ser identificada de forma distinguível, a partir da qual pode ser realizada a estimativa de frequência cardíaca. Nesse caso, a análise espectral foi realizada no sinal em sua completude. Complementarmente, as estimativas de frequência cardíaca realizadas por janela são dispostas na Figura 19.




Figura 17: Espectrogramas dos sinais cujas estimativas de frequência cardíaca resultaram no menor erro médio absoluto.

Fonte: autoria própria




Figura 18: Espectros de potência dos sinais cujas estimativas de frequência cardíaca resultaram no menor erro médio absoluto.

Fonte: autoria própria

Ademais, são apresentadas as curvas de erro absoluto médio dos métodos não supervisionados em comparação com os métodos supervisionados por janela para os dois vídeos na Figura 20. Pode-se observar como essas curvas de erro exibem comportamentos temporalmente semelhantes entre os dois grupos de métodos, com ocorrências coincidentes de aumento e redução do erro em múltiplas janelas consecutivas.




Figura 19: Estimativas de frequência cardíaca por janela dos sinais que resultaram no menor erro médio absoluto.

Fonte: autoria própria




Figura 20: Erro absoluto médio por janela dos métodos supervisionados e não supervisionados de cada vídeo da coleta 2.

Fonte: autoria própria

5 DISCUSSÃO PRELIMINAR

Com base no que foi disposto, verifica-se que a extração de sinais de fotopletismografia remota a partir de vídeos de pacientes internados em Unidades de Terapia Intensiva pode ser realizada por meio de métodos baseados em algoritmos e modelos matemáticos, denominados métodos não supervisionados, bem como pode ser realizada por meio de modelos baseados em aprendizado profundo, referidos como métodos supervisionados. Esses métodos resultam em uma onda de pulso de volume sanguíneo a qual possui correspondência identificável com o sinal de fotopletismografia convencional e a partir da qual podem ser estimados valores de frequência cardíaca. No entanto, artefatos de iluminação e de movimento impactam de forma significativa na qualidade do sinal extraído, como foi possível verificar a partir dos resultados da coleta de validação, na qual as estimativas de frequência cardíaca extraídas do vídeo com maior incidência desses elementos apresentaram maior erro médio absoluto em relação aos valores de referência obtidos por meio do eletrocardiograma, quando comparado às estimativas advindas do vídeo em que o paciente permaneceu imóvel. De maneira complementar, a análise do erro médio por janela das estimativas de frequência cardíaca realizada tanto nos dados da coleta de validação, quanto nos dados da coleta preliminar, permite identificar valores maiores de erro em janelas nas quais há mudanças expressivas de iluminação ou da posição do rosto, o que reforça o impacto desses artefatos.

Além disso, o sinal que pode ser obtido por métodos de fotopletismografia remota é influenciado pela detecção e rastreamento da região de interesse, o que foi verificado no processamento dos dados da coleta preliminar. Nesse caso, o sinal extraído a partir do vídeo do paciente 1 apresentou um baixo índice de correlação com o sinal de fotopletismografia de referência, bem como as estimativas de frequência cardíaca realizadas resultaram nos maiores valores de erro médio absoluto entre todos os resultados. Isso pode ser explicado devido ao fato de que a ferramenta de detecção de face utilizada não reconheceu o rosto do paciente, possivelmente devido à oclusão significativa dessa região, em decorrência da presença de equipamentos de suporte ventilatório. Assim, para todos os métodos, foram utilizados os quadros completos do vídeo como entrada, o que gera o aumento da

incidência de elementos de ruído e, consequentemente, a degradação do sinal, o que é atenuado quando apenas a região de interesse é introduzida aos modelos. Observa-se, ainda, que nesse caso o sinal de PPG de referência difere da forma de onda fotopletiomográfica convencional esperada, o que pode decorrer de fatores fisiológicos relacionados à condição clínica do paciente, de modo que são necessárias análises mais aprofundadas para esclarecer esse tipo de influência sobre o sinal.

Por fim, a partir dos valores de erro médio absoluto para as estimativas de frequência cardíaca tanto a partir dos dados da coleta preliminar quanto da coleta de validação, nota-se que os métodos supervisionados apresentaram resultados comparáveis aos métodos não supervisionados, apesar de demandarem maior custo computacional para inferência. Ademais, entre os métodos supervisionados, modelos de mesma estrutura treinados em bases de dados diferentes resultaram em estimativas com erros expressivamente diferentes em relação à referência, o que demonstra a influência do conjunto de dados de treinamento no desempenho dos modelos em situações realistas. Por conseguinte, ambos os tipos de método de extração de sinais de fotopletiomografia remota apresentam métricas de erro e valores para a razão sinal-ruído que reafirmam o potencial de aplicação desse tipo de tecnologia em situações clínicas. Faz-se necessário, todavia, a análise em uma quantidade maior de amostras para que conclusões mais detalhadas possam ser esclarecidas.

A diferença da câmera em cada procedimento se dá devido à disponibilidade, dado que a coleta preliminar foi realizada com uma câmera provisória disponibilizada pela empresa fabricante, enquanto as outras coletas dependem da aquisição definitiva do segundo modelo. Ademais, a escolha da utilização de uma câmera industrial é baseada sobretudo no objetivo de garantir a aquisição de dados sem compressão, já que esse é um fator que deteriora significativamente a relação sinal-ruído, conforme discutido na Seção 2.4. Além disso, a obtenção de imagens de boa qualidade em um sistema cujos parâmetros do sensor óptico podem ser configurados de forma acessível garante a robustez na análise dos algoritmos.

REFERÊNCIAS

- ACHARYA, U. R.; JOSEPH, P. K.; KANNATHAL, N.; LIM, C. M.; SURI, J. S. Heart rate variability: a review. **Medical & biological engineering & computing**, Institution of Electrical Engineers, Savoy Pl. London WC 2 R 0 BL UK, v. 44, n. 12, p. 1031–1051, 2006.
- AGUIAR, L. M. M.; MARTINS, G. d. S.; VALDUGA, R.; GEREZ, A. P.; CARMO, E. C. d.; CUNHA, K. d. C.; CIPRIANO, G. F. B.; SILVA, M. L. d. Perfil de unidades de terapia intensiva adulto no brasil: revisão sistemática de estudos observacionais. **Revista Brasileira de Terapia Intensiva**, SciELO Brasil, v. 33, n. 4, p. 624–634, 2021.
- AL-NAJI, A.; PERERA, A. G.; CHAHL, J. Remote monitoring of cardiorespiratory signals from a hovering unmanned aerial vehicle. **Biomedical engineering online**, Springer, v. 16, n. 1, p. 101, 2017.
- ALLEN, J. Photoplethysmography and its application in clinical physiological measurement. **Physiological measurement**, IoP Publishing, v. 28, n. 3, p. R1, 2007.
- BAUTISTA, M. J.; KOWAL, M.; CAVE, D. G.; DOWNEY, C.; JAYNE, D. G. Clinical applications of contactless photoplethysmography for monitoring in adults: A systematic review and meta-analysis. **Journal of Clinical and Translational Science**, Cambridge University Press, v. 7, n. 1, p. e129, 2023.
- BERGER, R. D.; AKSELROD, S.; GORDON, D.; COHEN, R. J. An efficient algorithm for spectral analysis of heart rate variability. **IEEE Transactions on biomedical engineering**, IEEE, n. 9, p. 900–904, 1986.
- BIAN, M.; PENG, B.; WANG, W.; DONG, J. An accurate lstm based video heart rate estimation method. In: SPRINGER. **Chinese Conference on Pattern Recognition and Computer Vision (PRCV)**. [S.l.], 2019. p. 409–417.
- BLACKFORD, E. B.; ESTEPP, J. R. Effects of frame rate and image resolution on pulse rate measured using multiple camera imaging photoplethysmography. In: SPIE. **Medical Imaging 2015: Biomedical Applications in Molecular, Structural, and Functional Imaging**. [S.l.], 2015. v. 9417, p. 639–652.
- BOBBIA, S.; MACWAN, R.; BENEZETH, Y.; MANSOURI, A.; DUBOIS, J. Unsupervised skin tissue segmentation for remote photoplethysmography. **Pattern recognition letters**, Elsevier, v. 124, p. 82–90, 2019.
- BOCCIGNONE, G.; D’AMELIO, A.; GHEZZI, O.; GROSSI, G.; LANZAROTTI, R. An evaluation of non-contact photoplethysmography-based methods for remote respiratory rate estimation. **Sensors**, MDPI, v. 23, n. 7, p. 3387, 2023.
- BONDARENKO, M.; MENON, C.; ELGENDI, M. The role of face regions in remote photoplethysmography for contactless heart rate monitoring. **npj Digital Medicine**, Nature Publishing Group UK London, v. 8, n. 1, p. 479, 2025.

- BOTINA-MONSALVE, D.; BENEZETH, Y.; MACWAN, R.; PIERRART, P.; PARRA, F.; NAKAMURA, K.; GOMEZ, R.; MITERAN, J. Long short-term memory deep-filter in remote photoplethysmography. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops**. [S.l.: s.n.], 2020. p. 306–307.
- BOUSEFSAF, F.; MAAOUI, C.; PRUSKI, A. Automatic selection of webcam photoplethysmographic pixels based on lightness criteria. **Journal of Medical and Biological Engineering**, Springer, v. 37, n. 3, p. 374–385, 2017.
- CARDOSO, J.-F. High-order contrasts for independent component analysis. **Neural computation**, MIT Press, v. 11, n. 1, p. 157–192, 1999.
- CASADO, C. A.; LÓPEZ, M. B. Face2ppg: An unsupervised pipeline for blood volume pulse extraction from faces. **IEEE Journal of Biomedical and Health Informatics**, IEEE, v. 27, n. 11, p. 5530–5541, 2023.
- CASALINO, G.; CASTELLANO, G.; ZAZA, G. A mhealth solution for contact-less self-monitoring of blood oxygen saturation. In: IEEE. **2020 IEEE Symposium on Computers and Communications (ISCC)**. [S.l.], 2020. p. 1–7.
- CHARLTON, P. H.; BONNICI, T.; TARASSENKO, L.; CLIFTON, D. A.; BEALE, R.; WATKINSON, P. J. An assessment of algorithms to estimate respiratory rate from the electrocardiogram and photoplethysmogram. **Physiological measurement**, IOP Publishing, v. 37, n. 4, p. 610–626, 2016.
- CHEN, W.; MCDUFF, D. Deepphys: Video-based physiological measurement using convolutional attention networks. In: **Proceedings of the european conference on computer vision (ECCV)**. [S.l.: s.n.], 2018. p. 349–365.
- CHEN, W.; YI, Z.; LIM, L. J. R.; LIM, R. Q. R.; ZHANG, A.; QIAN, Z.; HUANG, J.; HE, J.; LIU, B. Deep learning and remote photoplethysmography powered advancements in contactless physiological measurement. **Frontiers in bioengineering and biotechnology**, Frontiers Media SA, v. 12, p. 1420100, 2024.
- CHENG, C.-H.; WONG, K.-L.; CHIN, J.-W.; CHAN, T.-T.; SO, R. H. Deep learning methods for remote heart rate measurement: A review and future research agenda. **sensors**, MDPI, v. 21, n. 18, p. 6296, 2021.
- CHENG, J.; CHEN, X.; XU, L.; WANG, Z. J. Illumination variation-resistant video-based heart rate measurement using joint blind source separation and ensemble empirical mode decomposition. **IEEE journal of biomedical and health informatics**, IEEE, v. 21, n. 5, p. 1422–1433, 2016.
- COUDERC, J.-P.; KYAL, S.; MESTHA, L. K.; XU, B.; PETERSON, D. R.; XIA, X.; HALL, B. Detection of atrial fibrillation using contactless facial video monitoring. **Heart rhythm**, Elsevier, v. 12, n. 1, p. 195–201, 2015.
- DALTRO-OLIVEIRA, R.; QUINTAIROS, A.; SANTOS, L.; AMADO, F.; SALLUH, J.; JR, A. N. Global disparities in scientific publications: A 5-year analysis of 10 critical care journals. **Critical Care and Resuscitation**, Elsevier, v. 27, n. 4, p. 100137, 2025.

- DOSOVITSKIY, A.; BEYER, L.; KOLESNIKOV, A.; WEISSENBORN, D.; ZHAI, X.; UNTERTHINER, T.; DEGHANI, M.; MINDERER, M.; HEIGOLD, G.; GELLY, S.; USZKOREIT, J.; HOULSBY, N. **An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale**. 2021. Disponível em: <<https://arxiv.org/abs/2010.11929>>.
- EDE, J.; VOLLAM, S.; DARBYSHIRE, J. L.; GIBSON, O.; TARASSENKO, L.; WATKINSON, P. Non-contact vital sign monitoring of patients in an intensive care unit: A human factors analysis of staff expectations. **Applied Ergonomics**, Elsevier, v. 90, p. 103149, 2021.
- ELLIOTT, M.; COVENTRY, A. Critical care: the eight vital signs of patient monitoring. **British Journal of Nursing**, MA Healthcare London, v. 21, n. 10, p. 621–625, 2012.
- FALLOW, B. A.; TARUMI, T.; TANAKA, H. Influence of skin type and wavelength on light wave reflectance. **Journal of clinical monitoring and computing**, Springer, v. 27, n. 3, p. 313–317, 2013.
- FAN, X.; LIU, F.; ZHANG, J.; GAO, T.; FAN, Z.; HUANG, Z.; XUE, W.; ZHANG, J. Remote photoplethysmography based on reflected light angle estimation. **Physiological Measurement**, IOP Publishing, v. 45, n. 3, p. 035005, 2024.
- FAN, X.; YE, Q.; YANG, X.; CHOUDHURY, S. D. Robust blood pressure estimation using an rgb camera. **Journal of Ambient Intelligence and Humanized Computing**, Springer, v. 11, n. 11, p. 4329–4336, 2020.
- FENG, L.; PO, L.-M.; XU, X.; LI, Y.; MA, R. Motion-resistant remote imaging photoplethysmography based on the optical properties of skin. **IEEE Transactions on Circuits and Systems for Video Technology**, IEEE, v. 25, n. 5, p. 879–891, 2014.
- FITZPATRICK, T. B. The validity and practicality of sun-reactive skin types i through vi. **Archives of dermatology**, American Medical Association, v. 124, n. 6, p. 869–871, 1988.
- GENT, P. van; FARAH, H.; NES, N.; AREM, B. Heart rate analysis for human factors: Development and validation of an open source toolkit for noisy naturalistic heart rate data. In: . [S.l.: s.n.], 2018.
- GS, Y. K.; BHATTACHARYA, S.; AISHWARYA, N. Remote photoplethysmography (rppg) for contactless blood oxygen saturation monitoring. In: IEEE. **2024 IEEE International Conference on Electronics, Computing and Communication Technologies (CONECCT)**. [S.l.], 2024. p. 1–6.
- GUAZZI, A. R.; VILLARROEL, M.; JORGE, J.; DALY, J.; FRISE, M. C.; ROBBINS, P. A.; TARASSENKO, L. Non-contact measurement of oxygen saturation with an rgb camera. **Biomedical optics express**, Optical Society of America, v. 6, n. 9, p. 3320–3338, 2015.
- GULER, S.; OZTURK, O.; GOLPARVAR, A.; DOGAN, H.; YAPICI, M. K. Effects of illuminance intensity on the green channel of remote photoplethysmography (rppg) signals. **Physical and Engineering Sciences in Medicine**, Springer, v. 45, n. 4, p. 1317–1323, 2022.

HAAN, G. D.; JEANNE, V. Robust pulse rate from chrominance-based rppg. **IEEE transactions on biomedical engineering**, IEEE, v. 60, n. 10, p. 2878–2886, 2013.

HAAN, G. D.; LEEST, A. V. Improved motion robustness of remote-ppg by using the blood volume pulse signature. **Physiological measurement**, IOP Publishing, v. 35, n. 9, p. 1913–1926, 2014.

HAMOUD, B.; KASHEVNIK, A.; OTHMAN, W.; SHILOV, N. Neural network model combination for video-based blood pressure estimation: New approach and evaluation. **Sensors**, MDPI, v. 23, n. 4, p. 1753, 2023.

HARFORD, M.; CATHERALL, J.; GERRY, S.; YOUNG, J. D.; WATKINSON, P. Availability and performance of image-based, non-contact methods of monitoring heart rate, blood pressure, respiratory rate, and oxygen saturation: a systematic review. **Physiological measurement**, IOP Publishing, v. 40, n. 6, p. 06TR01, 2019.

HASSAN, M. A.; MALIK, A. S.; SAAD, N.; FOFI, D.; MERIAUDEAU, F. Effect of motion artifact on digital camera based heart rate measurement. In: IEEE. **2017 39th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.], 2017. p. 2851–2854.

HU, M.; QIAN, F.; GUO, D.; WANG, X.; HE, L.; REN, F. Eta-rppgnet: Effective time-domain attention network for remote heart rate measurement. **IEEE Transactions on Instrumentation and Measurement**, IEEE, v. 70, p. 1–12, 2021.

HUANG, B.; LIN, C.-L.; CHEN, W.; JUANG, C.-F.; WU, X. A novel one-stage framework for visual pulse rate estimation using deep neural networks. **Biomedical Signal Processing and Control**, v. 66, p. 102387, 2021. ISSN 1746-8094. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1746809420304936>>.

IOZZIA, L.; LÁZARO, J.; GIL, E.; CERINA, L.; MAINARDI, L.; LAGUNA, P. Respiratory rate detection using a camera as contactless sensor. In: IEEE. **2017 Computing in Cardiology (CinC)**. [S.l.], 2017. p. 1–4.

IUCHI, K.; MIYAZAKI, R.; CARDOSO, G. C.; OGAWA-OCHIAI, K.; TSUMURA, N. Blood pressure estimation by spatial pulse-wave dynamics in a facial video. **Biomedical Optics Express**, Optica Publishing Group, v. 13, n. 11, p. 6035–6047, 2022.

JORGE, J.; VILLARROEL, M.; TOMLINSON, H.; GIBSON, O.; DARBYSHIRE, J. L.; EDE, J.; HARFORD, M.; YOUNG, J. D.; TARASSENKO, L.; WATKINSON, P. Non-contact physiological monitoring of post-operative patients in the intensive care unit. **NPJ digital medicine**, Nature Publishing Group UK London, v. 5, n. 1, p. 4, 2022.

KARTYNNIK, Y.; ABLAVATSKI, A.; GRISHCHENKO, I.; GRUNDMANN, M. Real-time facial surface geometry from monocular video on mobile gpus. **arXiv preprint arXiv:1907.06724**, 2019.

KHAN, S. S.; MOSTAFA, N. Representation biases in remote photoplethysmography datasets—a narrative review. **Applied Computing and Informatics**, Emerald Publishing Limited, p. 1–16, 2025.

- KHANAM, F.-T.-Z.; AL-NAJI, A.; CHAHL, J. Remote monitoring of vital signs in diverse non-clinical and clinical scenarios using computer vision systems: A review. **Applied Sciences**, MDPI, v. 9, n. 20, p. 4474, 2019.
- KIM, D.-Y.; LEE, K.; SOHN, C.-B. Assessment of roi selection for facial video-based rppg. **Sensors**, MDPI, v. 21, n. 23, p. 7923, 2021.
- KLINKER, G. J.; SHAFER, S. A.; KANADE, T. The measurement of highlights in color images. **International Journal of Computer Vision**, Springer, v. 2, n. 1, p. 7–32, 1988.
- KONG, L.; ZHAO, Y.; DONG, L.; JIAN, Y.; JIN, X.; LI, B.; FENG, Y.; LIU, M.; LIU, X.; WU, H. Non-contact detection of oxygen saturation based on visible light imaging device using ambient light. **Optics express**, Optical Society of America, v. 21, n. 15, p. 17464–17471, 2013.
- KUMAR, M.; VEERARAGHAVAN, A.; SABHARWAL, A. Distanceppg: Robust non-contact vital signs monitoring using a camera. **Biomedical optics express**, Optical Society of America, v. 6, n. 5, p. 1565–1588, 2015.
- KWON, S.; KIM, J.; LEE, D.; PARK, K. Roi analysis for remote photoplethysmography on facial video. In: IEEE. **2015 37th Annual international conference of the IEEE engineering in medicine and biology society (EMBC)**. [S.l.], 2015. p. 4938–4941.
- LAM, A.; KUNO, Y. Robust heart rate measurement from video using select random patches. In: **Proceedings of the IEEE international conference on computer vision**. [S.l.: s.n.], 2015. p. 3640–3648.
- LAURIE, J.; HIGGINS, N.; PEYNOT, T.; ROBERTS, J. Dedicated exposure control for remote photoplethysmography. **IEEE Access**, IEEE, v. 8, p. 116642–116652, 2020.
- LEE, E.; CHEN, E.; LEE, C.-Y. Meta-rppg: Remote heart rate estimation using a transductive meta-learner. In: SPRINGER. **European conference on computer vision**. [S.l.], 2020. p. 392–409.
- LEE, H.; LEE, J.; KWON, Y.; KWON, J.; PARK, S.; SOHN, R.; PARK, C. Multitask siamese network for remote photoplethysmography and respiration estimation. **Sensors**, MDPI, v. 22, n. 14, p. 5101, 2022.
- LEE, R. J.; SIVAKUMAR, S.; LIM, K. H. Review on remote heart rate measurements using photoplethysmography. **Multimedia Tools and Applications**, Springer, v. 83, n. 15, p. 44699–44728, 2024.
- LEWANDOWSKA, M.; NOWAK, J. Measuring pulse rate with a webcam. **Journal of Medical Imaging and Health Informatics**, American Scientific Publishers, v. 2, n. 1, p. 87–92, 2012.
- LI, P.; BENEZETH, Y.; MACWAN, R.; NAKAMURA, K.; GOMEZ, R.; LI, C.; YANG, F. Video-based pulse rate variability measurement using periodic variance maximization and adaptive two-window peak detection. **Sensors**, MDPI, v. 20, n. 10, p. 2752, 2020.

- LI, X.; CHEN, J.; ZHAO, G.; PIETIKAINEN, M. Remote heart rate measurement from face videos under realistic situations. In: **Proceedings of the IEEE conference on computer vision and pattern recognition**. [S.l.: s.n.], 2014. p. 4264–4271.
- LI, Y.; WANG, J.; PAN, C.; PANG, J.; CHEN, Y.; LI, K. Improving signal quality for remote photoplethysmography by suppression of motion and lighting effects. In: IEEE. **2025 47th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.], 2025. p. 1–6.
- LIN, Y.-C.; LIN, Y.-H. A study of color illumination effect on the snr of rppg signals. In: IEEE. **2017 39th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.], 2017. p. 4301–4304.
- LIU, S.-Q.; YUEN, P. C. A general remote photoplethysmography estimator with spatio-temporal convolutional network. In: IEEE. **2020 15th IEEE international conference on automatic face and gesture recognition (FG 2020)**. [S.l.], 2020. p. 481–488.
- LIU, X.; FROMM, J.; PATEL, S.; MCDUFF, D. Multi-task temporal shift attention networks for on-device contactless vitals measurement. **Advances in Neural Information Processing Systems**, v. 33, p. 19400–19411, 2020.
- LIU, X.; HILL, B.; JIANG, Z.; PATEL, S.; MCDUFF, D. Efficientphys: Enabling simple, fast and accurate camera-based cardiac measurement. In: **Proceedings of the IEEE/CVF winter conference on applications of computer vision**. [S.l.: s.n.], 2023. p. 5008–5017.
- LIU, X.; NARAYANSWAMY, G.; PARUCHURI, A.; ZHANG, X.; TANG, J.; ZHANG, Y.; WANG, Y.; SENGUPTA, S.; PATEL, S.; MCDUFF, D. rppg-toolbox: Deep remote ppg toolbox. **arXiv preprint arXiv:2210.00716**, 2022.
- LIU, X.; YANG, X.; MENG, Z.; WANG, Y.; ZHANG, J.; WONG, A. Manet: A motion-driven attention network for detecting the pulse from a facial video with drastic motions. In: **Proceedings of the IEEE/CVF International Conference on Computer Vision**. [S.l.: s.n.], 2021. p. 2385–2390.
- LU, H.; HAN, H. Nas-hr: Neural architecture search for heart rate estimation from face videos. **Virtual Reality & Intelligent Hardware**, Elsevier, v. 3, n. 1, p. 33–42, 2021.
- LU, H.; HAN, H.; ZHOU, S. K. Dual-gan: Joint bvp and noise modeling for remote physiological measurement. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2021. p. 12404–12413.
- LUGARESI, C.; TANG, J.; NASH, H.; MCCLANAHAN, C.; UBOWEJA, E.; HAYS, M.; ZHANG, F.; CHANG, C.-L.; YONG, M. G.; LEE, J. et al. Mediapipe: A framework for building perception pipelines. **arXiv preprint arXiv:1906.08172**, 2019.
- LUGUERN, D.; PERCHE, S.; BENEZETH, Y.; MOSER, V.; DUNBAR, L. A.; BRAUN, F.; LEMKADDEM, A.; NAKAMURA, K.; GOMEZ, R.; DUBOIS, J. An assessment of algorithms to estimate respiratory rate from the remote photoplethysmogram. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops**. [S.l.: s.n.], 2020. p. 304–305.

- MAKI, Y.; MONNO, Y.; YOSHIZAKI, K.; TANAKA, M.; OKUTOMI, M. Inter-beat interval estimation from facial video based on reliability of bvp signals. In: IEEE. **2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.], 2019. p. 6525–6528.
- MALIK, M.; BIGGER, J. T.; CAMM, A. J.; KLEIGER, R. E.; MALLIANI, A.; MOSS, A. J.; SCHWARTZ, P. J. Heart rate variability: Standards of measurement, physiological interpretation, and clinical use. **European heart journal**, Oxford University Press, v. 17, n. 3, p. 354–381, 1996.
- MCDUFF, D. J.; BLACKFORD, E. B.; ESTEPP, J. R. The impact of video compression on remote cardiac pulse measurement using imaging photoplethysmography. In: IEEE. **2017 12th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2017)**. [S.l.], 2017. p. 63–70.
- MCDUFF, D. J.; ESTEPP, J. R.; PIASECKI, A. M.; BLACKFORD, E. B. A survey of remote optical photoplethysmographic imaging methods. In: IEEE. **2015 37th annual international conference of the IEEE engineering in medicine and biology society (EMBC)**. [S.l.], 2015. p. 6398–6404.
- MOÇO, A.; VERKRUYSSSE, W. Pulse oximetry based on photoplethysmography imaging with red and green light: Calibratability and challenges. **Journal of clinical monitoring and computing**, Springer, v. 35, n. 1, p. 123–133, 2021.
- MUKKAMALA, R.; HAHN, J.-O.; INAN, O. T.; MESTHA, L. K.; KIM, C.-S.; TÖREYIN, H.; KYAL, S. Toward ubiquitous blood pressure monitoring via pulse transit time: theory and practice. **IEEE transactions on biomedical engineering**, IEEE, v. 62, n. 8, p. 1879–1901, 2015.
- MURAKAMI, K.; YOSHIOKA, M.; OZAWA, J. Non-contact pulse transit time measurement using imaging camera, and its relation to blood pressure. In: IEEE. **2015 14th IAPR International Conference on Machine Vision Applications (MVA)**. [S.l.], 2015. p. 414–417.
- NAGAR, S.; HASEGAWA-JOHNSON, M.; BEISER, D. G.; AHUJA, N. R2i-rppg: A robust region of interest selection method for remote photoplethysmography to extract heart rate. **arXiv preprint arXiv:2410.15851**, 2024.
- NAPOLEAN, Y.; MARWADE, A.; TOMEN, N.; ALKEMADE, P.; EIJSVOGELS, T.; GEMERT, J. C. van. Heart rate estimation in intense exercise videos. In: IEEE. **2022 IEEE International Conference on Image Processing (ICIP)**. [S.l.], 2022. p. 3933–3937.
- NIU, X.; HAN, H.; SHAN, S.; CHEN, X. Synrhythm: Learning a deep heart rate estimator from general to specific. In: IEEE. **2018 24th international conference on pattern recognition (ICPR)**. [S.l.], 2018. p. 3580–3585.
- NIU, X.; SHAN, S.; HAN, H.; CHEN, X. Rhythmnet: End-to-end heart rate estimation from face via spatial-temporal representation. **IEEE Transactions on Image Processing**, IEEE, v. 29, p. 2409–2423, 2019.

- NOWARA, E.; MCDUFF, D. Combating the impact of video compression on non-contact vital sign measurement using supervised learning. In: **Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops**. [S.l.: s.n.], 2019. p. 0–0.
- NOWARA, E. M.; MCDUFF, D.; VEERARAGHAVAN, A. A meta-analysis of the impact of skin tone and gender on non-contact photoplethysmography measurements. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops**. [S.l.: s.n.], 2020. p. 284–285.
- PAPAGEORGIOU, A.; HAAN, G. de. Adaptive gain tuning for robust remote pulse rate monitoring under changing light conditions. **Technische Universiteit Eindhoven**, 2014.
- PELÁEZ-COCA, M. D.; HERNANDO, A.; LÁZARO, J.; GIL, E. Impact of the ppg sampling rate in the pulse rate variability indices evaluating several fiducial points in different pulse waveforms. **IEEE journal of biomedical and health informatics**, IEEE, v. 26, n. 2, p. 539–549, 2021.
- PILZ, C. S.; ZAUNSEDER, S.; KRAJEWSKI, J.; BLAZEK, V. Local group invariance for heart rate estimation from face videos in the wild. In: **Proceedings of the IEEE conference on computer vision and pattern recognition workshops**. [S.l.: s.n.], 2018. p. 1254–1262.
- POH, M.-Z.; MCDUFF, D. J.; PICARD, R. W. Advancements in noncontact, multiparameter physiological measurements using a webcam. **IEEE transactions on biomedical engineering**, IEEE, v. 58, n. 1, p. 7–11, 2010.
- _____. Non-contact, automated cardiac pulse measurements using video imaging and blind source separation. **Optics express**, Optical Society of America, v. 18, n. 10, p. 10762–10774, 2010.
- QI, D.; TAN, W.; YAO, Q.; LIU, J. Yolo5face: Why reinventing a face detector. In: SPRINGER. **European Conference on Computer Vision**. [S.l.], 2022. p. 228–244.
- ROUAST, P. V.; ADAM, M. T.; CHIONG, R.; CORNFORTH, D.; LUX, E. Remote heart rate measurement using low-cost rgb face video: a technical literature review. **Frontiers of Computer Science**, Springer, v. 12, n. 5, p. 858–872, 2018.
- SABOKROU, M.; POURREZA, M.; LI, X.; FATHY, M.; ZHAO, G. Deep-hr: Fast heart rate estimation from face video under realistic conditions. **Expert Systems with Applications**, v. 186, p. 115596, 2021. ISSN 0957-4174. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417421009969>>.
- SANYAL, S.; NUNDY, K. K. Algorithms for monitoring heart rate and respiratory rate from the video of a user's face. **IEEE Journal of translational engineering in health and medicine**, IEEE, v. 6, p. 1–11, 2018.
- SCHÄFER, A.; VAGEDES, J. How accurate is pulse rate variability as an estimate of heart rate variability?: A review on studies comparing photoplethysmographic technology with an electrocardiogram. **International journal of cardiology**, Elsevier, v. 166, n. 1, p. 15–29, 2013.

- SCHRUMPF, F.; MÖNCH, C.; BAUSCH, G.; FUCHS, M. Exploiting weak head movements for camera-based respiration detection. In: IEEE. **2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)**. [S.l.], 2019. p. 6059–6062.
- SECERBEGOVIC, A.; BERGSLAND, J.; HALVORSEN, P. S.; SULJANOVIC, N.; MUJICIC, A.; BALASINGHAM, I. Blood pressure estimation using video plethysmography. In: IEEE. **2016 IEEE 13th international symposium on biomedical imaging (ISBI)**. [S.l.], 2016. p. 461–464.
- SELVARAJU, V.; SPICHER, N.; WANG, J.; GANAPATHY, N.; WARNECKE, J. M.; LEONHARDT, S.; SWAMINATHAN, R.; DESERNO, T. M. Continuous monitoring of vital signs using cameras: A systematic review. **Sensors**, MDPI, v. 22, n. 11, p. 4097, 2022.
- SINHAL, R.; SINGH, K.; RAGHUWANSHI, M. An overview of remote photoplethysmography methods for vital sign monitoring. In: SPRINGER. **Computer Vision and Machine Intelligence in Medical Image Analysis: International Symposium, ISCMM 2019**. [S.l.], 2019. p. 21–31.
- SONG, R.; CHEN, H.; CHENG, J.; LI, C.; LIU, Y.; CHEN, X. PulseGAN: Learning to generate realistic pulse waveforms in remote photoplethysmography. **IEEE Journal of Biomedical and Health Informatics**, IEEE, v. 25, n. 5, p. 1373–1384, 2021.
- SONG, R.; ZHANG, S.; CHENG, J.; LI, C.; CHEN, X. New insights on super-high resolution for video-based heart rate estimation with a semi-blind source separation method. **Computers in biology and medicine**, Elsevier, v. 116, p. 103535, 2020.
- SONG, R.; ZHANG, S.; LI, C.; ZHANG, Y.; CHENG, J.; CHEN, X. Heart rate estimation from facial videos using a spatiotemporal representation with convolutional neural networks. **IEEE Transactions on Instrumentation and Measurement**, IEEE, v. 69, n. 10, p. 7411–7421, 2020.
- ŠPETLÍK, R.; FRANC, V.; MATAS, J. Visual heart rate estimation with convolutional neural network. In: **Proceedings of the british machine vision conference, Newcastle, UK**. [S.l.: s.n.], 2018. p. 3–6.
- SPICHER, N.; KUKUK, M.; MADERWALD, S.; LADD, M. E. Initial evaluation of prospective cardiac triggering using photoplethysmography signals recorded with a video camera compared to pulse oximetry and electrocardiography at 7t mri. **Biomedical engineering online**, Springer, v. 15, n. 1, p. 126, 2016.
- STRICKER, R.; MÜLLER, S.; GROSS, H.-M. Non-contact video-based pulse rate measurement on a mobile service robot. In: IEEE. **The 23rd IEEE international symposium on robot and human interactive communication**. [S.l.], 2014. p. 1056–1062.
- SUN, Y.; HU, S.; AZORIN-PERIS, V.; KALAWSKY, R.; GREENWALD, S. Noncontact imaging photoplethysmography to effectively access pulse rate variability. **Journal of biomedical optics**, Society of Photo-Optical Instrumentation Engineers, v. 18, n. 6, p. 061205–061205, 2013.

- SUN, Y.; PAPIN, C.; AZORIN-PERIS, V.; KALAWSKY, R.; GREENWALD, S.; HU, S. Use of ambient light in remote photoplethysmographic systems: comparison between a high-performance camera and a low-cost webcam. **Journal of biomedical optics**, Society of Photo-Optical Instrumentation Engineers, v. 17, n. 3, p. 037005–037005, 2012.
- SUN, Y.; YANG, Y.-Y.; WU, B.-J.; HUANG, P.-W.; CHENG, S.-E.; WU, B.-F.; CHEN, C.-C. Contactless facial video recording with deep learning models for the detection of atrial fibrillation. **Scientific reports**, Nature Publishing Group UK London, v. 12, n. 1, p. 281, 2022.
- TAKANO, C.; OHTA, Y. Heart rate measurement based on a time-lapse image. **Medical engineering & physics**, IOP Publishing, v. 29, n. 8, p. 853–857, 2007.
- TARASSENKO, L.; VILLARROEL, M.; GUAZZI, A.; JORGE, J.; CLIFTON, D.; PUGH, C. Non-contact video-based vital sign monitoring using ambient light and autoregressive models. **Physiological measurement**, IOP Publishing, v. 35, n. 5, p. 807, 2014.
- TOMASI, C.; KANADE, T. Detection and tracking of point features. **Int J Comput Vis**, v. 9, n. 137–154, p. 3, 1991.
- TRUMPP, A.; RASCHE, S.; WEDEKIND, D.; RUDOLF, M.; MALBERG, H.; MATSCHKE, K.; ZAUNSEDER, S. Relation between pulse pressure and the pulsation strength in camera-based photoplethysmograms. 2017.
- TSOU, Y.-Y.; LEE, Y.-A.; HSU, C.-T.; CHANG, S.-H. Siamese-rppg network: Remote photoplethysmography signal estimation from face videos. In: **Proceedings of the 35th annual ACM symposium on applied computing**. [S.l.: s.n.], 2020. p. 2066–2073.
- TSOURI, G. R.; LI, Z. On the benefits of alternative color spaces for noncontact heart rate measurements using standard red-green-blue cameras. **Journal of biomedical optics**, Society of Photo-Optical Instrumentation Engineers, v. 20, n. 4, p. 048002–048002, 2015.
- VERKRUYSSSE, W.; SVAASAND, L. O.; NELSON, J. S. Remote plethysmographic imaging using ambient light. **Optics express**, Optical Society of America, v. 16, n. 26, p. 21434–21445, 2008.
- VILLARROEL, M.; GUAZZI, A.; JORGE, J.; DAVIS, S.; WATKINSON, P.; GREEN, G.; SHENVI, A.; MCCORMICK, K.; TARASSENKO, L. Continuous non-contact vital sign monitoring in neonatal intensive care unit. **Healthcare technology letters**, Wiley Online Library, v. 1, n. 3, p. 87–91, 2014.
- VILLARROEL, M.; JORGE, J.; MEREDITH, D.; SUTHERLAND, S.; PUGH, C.; TARASSENKO, L. Non-contact vital-sign monitoring of patients undergoing haemodialysis treatment. **Scientific reports**, Nature Publishing Group UK London, v. 10, n. 1, p. 18529, 2020.
- VILLARROEL, M.; JORGE, J.; PUGH, C.; TARASSENKO, L. Non-contact vital sign monitoring in the clinic. In: **IEEE. 2017 12th IEEE international conference on automatic face & gesture recognition (FG 2017)**. [S.l.], 2017. p. 278–285.

- VIOLA, P.; JONES, M. Rapid object detection using a boosted cascade of simple features. In: IEEE. **Proceedings of the 2001 IEEE computer society conference on computer vision and pattern recognition. CVPR 2001**. [S.l.], 2001. v. 1, p. I–I.
- VIOLA, P.; JONES, M. J. Robust real-time face detection. **International journal of computer vision**, Springer, v. 57, n. 2, p. 137–154, 2004.
- WANG, W.; BRINKER, A. C. D.; STUIJK, S.; HAAN, G. D. Algorithmic principles of remote ppg. **IEEE Transactions on Biomedical Engineering**, IEEE, v. 64, n. 7, p. 1479–1491, 2016.
- WANG, W.; SHAN, C. Impact of makeup on remote-ppg monitoring. **Biomedical Physics & Engineering Express**, IOP Publishing, v. 6, n. 3, p. 035004, 2020.
- WANG, W.; STUIJK, S.; HAAN, G. D. Exploiting spatial redundancy of image sensor for motion robust rppg. **IEEE transactions on Biomedical Engineering**, IEEE, v. 62, n. 2, p. 415–425, 2014.
- _____. A novel algorithm for remote photoplethysmography: Spatial subspace rotation. **IEEE transactions on biomedical engineering**, IEEE, v. 63, n. 9, p. 1974–1984, 2015.
- WEI, B.; HE, X.; ZHANG, C.; WU, X. Non-contact, synchronous dynamic measurement of respiratory rate and heart rate based on dual sensitive regions. **Biomedical engineering online**, Springer, v. 16, n. 1, p. 17, 2017.
- WU, B.-F.; WU, B.-J.; CHENG, S.-E.; SUN, Y.; CHUNG, M.-L. Motion-robust atrial fibrillation detection based on remote-photoplethysmography. **IEEE Journal of Biomedical and Health Informatics**, IEEE, v. 27, n. 6, p. 2705–2716, 2022.
- WU, B.-F.; WU, B.-J.; TSAI, B.-R.; HSU, C.-P. A facial-image-based blood pressure measurement system without calibration. **IEEE Transactions on Instrumentation and Measurement**, IEEE, v. 71, p. 1–13, 2022.
- WU, Y.-C.; CHIU, L.-W.; WU, B.-F.; LIN, L. L.-C.; HO, T.-H.; CHUNG, M.-L.; WU, S.-F. Motion robust remote photoplethysmography measurement during exercise for contactless physical activity intensity detection. **IEEE Transactions on Instrumentation and Measurement**, IEEE, v. 72, p. 1–14, 2023.
- XIAO, H.; LIU, T.; SUN, Y.; LI, Y.; ZHAO, S.; AVOLIO, A. Remote photoplethysmography for heart rate measurement: A review. **Biomedical Signal Processing and Control**, Elsevier, v. 88, p. 105608, 2024.
- XU, S.; SUN, L.; ROHDE, G. K. Robust efficient estimation of heart rate pulse from video. **Biomedical optics express**, Optical Society of America, v. 5, n. 4, p. 1124–1135, 2014.
- YANG, Y.; LIU, C.; YU, H.; SHAO, D.; TSOW, F.; TAO, N. Motion robust remote photoplethysmography in cielab color space. **Journal of biomedical optics**, Society of Photo-Optical Instrumentation Engineers, v. 21, n. 11, p. 117001–117001, 2016.

YANG, Z.; WANG, H.; LIU, B.; LU, F. cbppgGAN: A generic enhancement framework for unpaired pulse waveforms in camera-based photoplethysmography. **IEEE Journal of Biomedical and Health Informatics**, IEEE, v. 28, n. 2, p. 598–608, 2023.

YU, Z.; LI, X.; ZHAO, G. Remote photoplethysmograph signal measurement from facial videos using spatio-temporal networks. **arXiv preprint arXiv:1905.02419**, 2019.

YU, Z.; PENG, W.; LI, X.; HONG, X.; ZHAO, G. Remote heart rate measurement from highly compressed facial videos: an end-to-end deep learning solution with video enhancement. In: **Proceedings of the IEEE/CVF international conference on computer vision**. [S.l.: s.n.], 2019. p. 151–160.

YU, Z.; SHEN, Y.; SHI, J.; ZHAO, H.; TORR, P. H.; ZHAO, G. Physformer: Facial video-based physiological measurement with temporal difference transformer. In: **Proceedings of the IEEE/CVF conference on computer vision and pattern recognition**. [S.l.: s.n.], 2022. p. 4186–4196.